



**YTU FEN EDEBİYAT
FAKULTESİ**

İSTATİSTİK BÖLÜMÜ

**HAVA KİRLİLİĞİ PARAMETRELERİNİN HALK
SAĞLIĞI ÜZERİNDEKİ ETKİLERİNİN MAKİNE
ÖĞRENMESİ İLE TAHMİN EDİLMESİ**

Işıl ÖZBOSTANCI

20123074

LİSANS BİTİRME TEZİ

**Danışman
Prof. Dr. Serpil KILIÇ DEPREN**

Haziran, 2026

Danışmanım Prof. Dr. Serpil KILIÇ DEPREN sorumluluğunda tarafımda hazırlanan “Hava Kirliliği Parametrelerinin Halk Sağlığı Üzerindeki Etkilerinin Makine Öğrenmesi İle Tahmin Edilmesi” başlıklı çalışmada veri toplama ve veri kullanımında gerekli yasal izinleri aldığımı, diğer kaynaklardan aldığım bilgileri ana metin ve referanslarda eksiksiz gösterdiğimi, araştırma verilerine ve sonuçlarına ilişkin çarpıtma ve/veya sahtecilik yapmadığımı, çalışmam süresince bilimsel araştırma ve etik ilkelerine uygun davrandığımı beyan ederim. Beyanımın aksinin ispatı halinde her türlü yasal sonucu kabul ederim.

Işıl ÖZBOSTANCI

İmza

TEŞEKKÜR

Bu çalışmanın fikir aşamasından tamamlanmasına kadar geçen süreçte, kıymetli bilgi ve birikimleriyle beni yönlendiren, akademik vizyonu ile bana her zaman yol gösteren ve yüksek beklentileriyle çalışmamın özgün bir değer kazanmasını sağlayan çok değerli tez danışmanım Prof. Dr. Serpil KILIÇ DEPREN'e en içten teşekkürlerimi sunarım.

Lisans eğitimim boyunca bizlere yalnızca teorik bilgiler vermekle kalmayıp analitik bakış açısı kazandıran Yıldız Teknik Üniversitesi, Fen-Edebiyat Fakültesi, İstatistik Bölümü'nün tüm değerli öğretim üyelerine ve araştırma görevlilerine de teşekkürlerimi sunarım.

Işıl ÖZBOSTANCI

İÇİNDEKİLER

TEŞEKKÜR	iii
SİMGE LİSTESİ	vi
KISALTMA LİSTESİ	vii
ŞEKİL LİSTESİ.....	viii
TABLO LİSTESİ.....	ix
ÖZET	x
ABSTRACT.....	xi
1 Giriş	12
1.1. Doğrusal Yaklaşımlar.....	12
1.2. Makine Öğrenmesi Yaklaşımları	12
1.3. Çalışmanın Amacı.....	13
2 Literatür Taraması.....	14
2.1. Hava Kirliliği ve Halk Sağlığı İlişkisi	14
2.2. Hava Kalitesi Tahmini ve Makine Öğrenmesi Yaklaşımları	16
2.3. Çalışmanın Katkısı	17
3 Veri Seti ve Yöntem	19
3.1. Veri Seti	19
3.1.2. Hava Kirlleticileri	19
3.1.2.1. Hava Kalitesi İndeksi (AQI).....	19
3.1.2.2. PM10 ve PM2.5.....	19
3.1.2.3. NO2	19
3.1.2.4. SO2	20
3.1.2.5. O3	20
3.1.3. Meteorolojik Koşullar	20
3.1.3.1. Sıcaklık (Temperature).....	20
3.1.3.2. Nem (Humidity)	21
3.1.3.3. Rüzgar Hızı (WindSpeed)	21
3.1.4. Sağlık Göstergeleri	21
3.1.4.1. Solunum Yolu Vakaları (RespiratoryCases)	21

3.1.4.2. Kardiyovasküler Vakalar (CardiovascularCases).....	21
3.1.4.3. Hastaneye Yatışlar (HospitalAdmissions).....	21
3.1.5. Bağımlı Değişkenler.....	21
3.1.5.1. Sağlık Etki Puanı (HealthImpactScore).....	21
3.1.5.2. Sağlık Etki Sınıfı (HealthImpactClass)	21
3.2. Tanımlayıcı İstatistikler	22
3.2.1. Hava Kirleticileri	22
3.2.2. Meteorolojik Koşullar	22
3.2.3. Sağlık Göstergeleri	23
3.3. Yöntem	25
3.3.1. Makine Öğrenmesi	25
3.3.1.1. Klasik Çoklu Doğrusal Regresyon Modeli	25
3.3.1.2. Rastgele Orman (Random Forest) Modeli	26
3.3.1.3. Lasso Regresyon Modeli	27
3.3.1.4. Ridge Regresyon Modeli.....	28
3.3.1.5. Destek Vektör Regresyon (SVR) Modeli.....	29
3.3.1.6. K-En Yakın Komşu (KNN) Modeli	30
3.3.1.7. Aşırı Gradyan Artırma (XGBoost) Modeli	31
4 BULGULAR VE TARTIŞMA.....	32
4.1. Klasik Çoklu Doğrusal Regresyon Modeli Bulguları.....	32
4.2. Lasso Regresyon Modeli Bulguları	35
4.3. Ridge Regresyon Modeli Bulguları	39
4.4. Rastgele Orman (Random Forest) Modeli Bulguları.....	42
4.5. K-En Yakın Komşu (KNN) Modeli Bulguları	45
4.6. Destek Vektör Regresyon (SVR) Modeli Bulguları	48
4.7. Aşırı Gradyan Artırma (XGBoost) Modeli Bulguları.....	50
4.8. Kurulan Modellerin Karşılaştırılması	53
4.9. Log Dönüşümü ve Standardizasyon İşlemi Bulguları	54
4.10. Duyarlılık Analizi Bulguları	54
5 SONUÇ.....	56
KAYNAKÇA	58

SİMGE LİSTESİ

$PM_{2.5}$	İnce Partikül Madde
PM_{10}	Kaba Partikül Madde
SO_2	Kükürt Dioksit Konsantrasyonu
NO_2	Azot Dioksit Konsantrasyonu
O_3	Ozon Konsantrasyonu
Y_i	i . Gözleme ait Bağımlı Değişken Değeri
X_{ij}	i . Gözleme ait j . Bağımsız Değişken Değeri
β_0	Regresyon Modelinin Sabit Terimi
$\beta_1, \dots, \beta_k$	Regresyon Katsayıları
ε_i	i . Gözleme ait rasgele hata terimi
$E(\varepsilon X)$	Hata Teriminin Koşullu Matematiksel Beklentisi
$Var(\varepsilon)$	Hata Teriminin Varyansı
σ^2	Sabit Varyans Değeri
I	Birim Matris
L_1	Mutlak Değer Tabanlı Ceza Fonksiyonu
L_2	Kare Tabanlı Ceza Fonksiyonu

KISALTMA LİSTESİ

vd.,	ve diğerleri
t.y.	Tarih yok
SVR	Destek Vektör Regresyonu
KNN	K- En Yakın Komşu
KÇDR	Klasik Çoklu Doğrusal Regresyon
Ppb	Milyonda bir
XGBoost	Aşırı Gradyan Artırma
vb.	ve benzeri
LSTM	Uzun Kısa Süreli Bellek
AQI	Hava Kalitesi İndeksi
ÇŞB	Çevre, Şehircilik ve İklim Değişikliği Bakanlığı
ALA	Amerikan Akciğer Derneği
UV	Ultraviyole
IEEE	Elektrik Elektronik Mühendisleri Enstitüsü
MSE	Ortalama Kare Hata
EKK	En Küçük Kareler
RMSE	Kök Ortalama Kare Hata
MAE	Ortalama Mutlak Hata
R^2	Belirtme Katsayısı

ŞEKİL LİSTESİ

Şekil 1. Korelasyon Matrisi	24
Şekil 2. VIF Değerler	32
Şekil 3. Sağlık Etki Skorunun Gerçek ve Tahmin Değerlerinin Dağılım Grafiği .	34
Şekil 4. KÇDR Modelinin Hata ve Tahmin Değerleri Dağılım Grafiği.....	34
Şekil 5. KÇDR Modelinin Hata Frekans Dağılım Histogramı	35
Şekil 6. Lasso Modeli Çapraz Doğrulamalı Log (λ) ve Hata Dağılım Grafiği	36
Şekil 7. Lasso Model Katsayı İnceleme Grafiği.....	37
Şekil 8. Lasso Modelde Parametre Katsayılarının Etki Gücü	37
Şekil 9. Sağlık Etki Skorunun Gerçek ve Tahmin Değerlerinin Dağılım Grafiği .	38
Şekil 10. Lasso Modelinin Hata Frekans Dağılım Histogramı.....	38
Şekil 11. Ridge Modeli Çapraz Doğrulamalı Log (λ) ve Hata Dağılım Grafiği ...	40
Şekil 12. Ridge Model λ' ya göre Katsayı Değişim Grafiği	40
Şekil 13. Ridge Modelde λ' ya göre Katsayı L_2 Normu Değişim Grafiği.....	41
Şekil 14. Ridge Modelinin Hata Frekans Dağılım Histogramı.....	41
Şekil 15. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği .	42
Şekil 16. Rastgele Orman Modeli Örnek Karar Ağacı Dallanma Yapısı.....	43
Şekil 17. Ağaç Sayısına Göre Hata Oranı Grafiği.....	44
Şekil 18. Değişkenlerin Önem Seviyeleri Grafiği	44
Şekil 19. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği .	45
Şekil 20. Rastgele Orman Modelinin Hata Frekans Dağılım Histogramı	45
Şekil 21. K - Komşu Sayısına Göre RMSE Değişim Grafiği.....	46
Şekil 22. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği .	47
Şekil 23. K -En Yakın Komşu Modelinin Hata Frekans Dağılım Histogramı	47
Şekil 24. K -En Yakın Komşu Kategorik Performans Matrisi	48
Şekil 25. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği .	49
Şekil 26. Destek Vektör Modelinin Hata Frekans Dağılım Histogram.....	49
Şekil 27. Değişkenlerin Önem Sıralaması.....	50
Şekil 28. XGBoost Modeli SHAP Değerleri ve Etki Yönü.....	51
Şekil 29. XGBoost Modeli Yakınsama Analizi	51
Şekil 30. Gerçek ve Tahmin Değerlerinin Olasılık Yoğunluk Grafiği.....	52
Şekil 31. Hastalık Türlerine Göre Değişkenlerin Önem Seviyeleri	52
Şekil 32. Modellerin Performans Metriklerinin Görselleştirilmesi	53

TABLO LİSTESİ

Tablo 1. Hava Kirliliği ve Halk Sağlığı İlişkisi Çalışmaları Tablosu	15
Tablo 2. Hava Kalitesi Tahmini ve Makine Öğrenmesi Çalışmaları Tablosu	17
Tablo 3. Veri Setindeki Değişkenler Tablosu	19
Tablo 4. Hava Kirleticilerinin Tanımlayıcı İstatistikleri	22
Tablo 5. Meteorolojik Koşulların Tanımlayıcı İstatistikleri.....	23
Tablo 6. Sağlık Göstergelerinin Tanımlayıcı İstatistikleri	24
Tablo 7. Çoklu Doğrusal Regresyon Modeli Katsayı Tahmin ve Güven Aralığı Sonuçları	32
Tablo 8. KÇDR Modelinin Tahmin Performansı Sonuçları.....	33
Tablo 9. Lasso Modeli Önem Sırasına Göre Optimize Edilmiş Katsayılar	35
Tablo 10. Lasso Modelinin Tahmin Performansı Sonuçları	36
Tablo 11. Ridge Modeli Önem Sırasına Göre Optimize Edilmiş Katsayılar	39
Tablo 12. Ridge Modelinin Tahmin Performansı Sonuçları	39
Tablo 13. Rastgele Orman Modelinin Tahmin Performansı Sonuçları	43
Tablo 14. K- En Yakın Komşu Modelinin Tahmin Performansı Sonuçları.....	46
Tablo 15. KNN Kategori Sayısına Göre Hata Oranı Tablosu	48
Tablo 16. Destek Vektör Regresyon Modelinin Tahmin Performansı Sonuçları	48
Tablo 17. XGBoost Modelinin Tahmin Performansı Sonuçları.....	50
Tablo 18. Kurulan Modellerin Tahmin Performansı Sonuçları.....	53
Tablo 19. Standardizasyon ve Log Dönüşümü R2 Değerleri.....	54
Tablo 20. Hava Kirleticilerinin %20 Azalması Senaryosu	54
Tablo 21. Hava Kirleticilerinin %10 Artması Senaryosu.....	54
Tablo 22. Meteorolojik Faktörlerin Değişimi Senaryosu.....	55
Tablo 23. Senaryoların Sağlık Etki Puanı Değişimi Tahmini	55

Hava Kirliliği Parametrelerinin Halk Sağlığı Üzerindeki Etkilerinin Makine Öğrenmesi ile Tahmin Edilmesi

Işıl Özbostancı

İstatistik Anabilim Dalı

Lisans Tezi

Danışman: Prof. Dr. Serpil KILIÇ DEPREN

Bu çalışmada, hava kirleticileri, meteorolojik faktörlerin ve sağlık göstergelerinin sağlık etki puanı üzerindeki etkileri makine öğrenmesi algoritmalarıyla incelenmiştir. Araştırmanın kapsamında; Klasik Çoklu Doğrusal Regresyon, Lasso, Ridge, Rastgele Orman, K-En Yakın Komşu, Destek Vektör Regresyonu (SVR) ve Aşırı Gradyan Artırma (XGBoost) modelleri matematiksel formülasyonlarıyla açıklanmıştır. Modellerin performans metrikleri ve varyansı açıklayabilme yetenekleri karşılaştırıldığında veri setini en iyi modelleyebilen algoritmaların XGBoost ve SVR modelleri olduğu belirlenmiştir. Bu modellerin tahmin başarısının optimizasyonu için uygulanan logaritmik dönüşüm ve standardizasyon işlemleri modellerin performanslarında istenilen düzeyde bir başarı sağlayamadığından analize orijinal modellerle devam edilmiştir. Son aşamada, hata seviyesi en düşük olan XGBoost ve SVR modelleriyle farklı senaryolar kurulmuş ve bu senaryoların önce hastalık türleri üzerindeki etkileri daha sonra ise sağlık etki puanı üzerindeki etkileri analiz edilip çalışmaya eklenmiştir.

Anahtar Kelimeler: Halk Sağlığı, Hava Kirliliği, Makine Öğrenmesi, XGBoost, SVR.

ABSTRACT

Prediction of the Effects of Air Pollution Parameters on Public Health with Machine Learning

Işıl Özbostancı

Department of Statistics

Undergraduate Thesis

Supervisor: Prof. Dr. Serpil KILIÇ DEPREN

In this study, the effects of air pollutants, meteorological factors, and health indicators on the health impact score were examined using machine learning algorithms. Within the scope of the research; Classical Multiple Linear Regression, Lasso, Ridge, Random Forest, K-Nearest Neighbours, Support Vector Regression (SVR), and Extreme Gradient Boosting (XGBoost) models were explained with their mathematical formulations. When the performance metrics and variance explanation capabilities of the models were compared, it was determined that the algorithms that could model the dataset best were the XGBoost and SVR models. Since the logarithmic transformation and standardization procedures applied for the optimization of the prediction success of these models could not provide the desired level of success in the performance of the models, the analysis was continued with the original models. In the final stage, different scenarios were established with the XGBoost and SVR models, which have the lowest error levels, and the effects of these scenarios first on disease types and then on the health impact score were analysed and added to the study.

Keywords: Public Health, Air Pollution, Machine Learning, XGBoost, SVR.

Gelişen dünyada kontrol edilemeyen şehirleşme, büyüme ve sanayileşme durumları uluslararası boyutta kritik çevresel sorunların başında gelen hava kirliliğini tetiklemektedir. Endüstriyel emisyonlar, araç egzozları, evsel ısınma vb. faaliyetler neticesinde atmosfere yayılan $PM_{2.5}$, PM_{10} , SO_2 , NO_2 , O_3 gibi kirleticiler hava kalitesini düşürmektedir (Pope vd., 2002). Bahsedilen kirleticilerin, insan sağlığı için direkt olarak tehdit olduğu klinik çalışmalarca kanıtlanmıştır (Dominici vd., 2006; Samet vd., 2000). Bu yüzden hava kirleticilerinin halk sağlığı üzerindeki potansiyel etkilerinin yüksek doğrulukla modellenebilmesi ve olabilecek senaryoların analizi insanlar üzerindeki riski öğrenip yönetebilme açısından önem göstermektedir.

1.1. Doğrusal Yaklaşımlar

Çevre ve halk sağlığı literatürü tarandığında, hava kalitesinin kötüleşmesinin büyük ölçekli etkilerini anlamlandırabilmek için çalışma içinde Klasik Çoklu Doğrusal Regresyon gibi parametrik yöntemlerden yararlanılmıştır. Bu doğrusal yöntemler bağımsız değişkenler arasındaki çoklu doğrusal bağlantı sorununda etkilenmiştir. Ayrıca doğrusal modeller kirleticiler ve halk sağlığı arasındaki doğrusal olmayan ilişkileri açıklamada yapısal sınırlarından ötürü yetersiz kalmışlardır (Gujarati & Porter, 2012; Hair vd., 2018). Meteorolojik faktörlerin hava kirleticilerle etkileşimleriyle ortaya çıkan doğrusal olmayan durumlarla birlikte doğrusal modellerin tahmin yetenekleri daha da düşmektedir (Montgomery vd., 2021). Doğrusal düzenlileştirme odaklı modellerden olan Lasso ve Ridge Regresyon modelleri ise çoklu doğrusal bağlantı sorununu çözebilse de doğrusal olmayan etkileşimleri açıklama kısmında yapıları gereği ideal model olamamışlardır (Tibshirani, 1996).

1.2. Makine Öğrenmesi Yaklaşımları

Günümüzde veri bilimi ve yapay zekanın gelişmesiyle birlikte makine öğrenme algoritmaları çevre ve halk sağlığı arasındaki ilişkileri daha iyi anlayıp daha güçlü model alternatifleri sunmaktadır. Uzaklık odaklı K- En Yakın Komşu, ağaç bazlı Rastgele Orman ve XGBoost ile geniş en iyileme fırsatı sağlayan Destek Vektör Regresyonu gibi algoritmalar söz konusu doğrusal olmayan ilişkileri modellemede oldukça başarılı olabilmektedir (Chen ve Guestrin, 2016; Smola ve Schölkopf, 2004). Makine öğrenmesi algoritmalarının sağladığı bu yöntemsel rahatlık; veri setindeki varyans değişimlerinin, ani değer değişimlerinin ve sınır değerlerin doğrusal modellere göre daha düşük hatayla tahminlenebilmesini sağlamaktadır. Ek olarak SHAP gibi yeni yaklaşımların vesilesiyle makine öğrenme modelleri hangi

açıklayıcı değişkenin hedef değişkende ne kadar marjinal etkisinin olduğunu takip edilmesine olanak sağlamıştır.

1.3. Çalışmanın Amacı

Bu çalışmanın amacı; atmosferdeki hava kirleticilerinin, meteorolojik faktörlerin ve hastalık bazındaki vaka yoğunluğunun halk sağlığı üzerindeki doğrusal ve doğrusal olmayan etkilerinin farklı modeller kıyaslanarak analiz edilmesidir. Araştırma yöntemleri kapsamında; doğrusal modellerden Klasik Çoklu Doğrusal Regresyon, Lasso Regresyon ve Ridge Regresyon modelleri ve makine öğrenmesi algoritmalarından K-En Yakın Komşu, Rastgele Orman, Destek Vektör Regresyonu ve XGBoost modelleri aynı zamanda aynı eğitim verisiyle eğitilerek veri seti içinden ayrılan aynı test verisi üzerinde uygulanmıştır. Eğitilmiş modellerin performansları hesaplanmış metriklerle karşılaştırılmıştır. Çalışmanın özgünleştirilmesi için veri seti varyansının açıklanabilirlik katsayısının en yüksek olduğu ve veri yapısını en iyi modelleyebilen iki model seçilerek ilgili modellerle değişkenleri grup olarak (hava kirleticileri, meteorolojik faktörler gibi) manipüle ederek varsayımsal senaryolarda halk sağlığı üzerindeki etkilerinin matematiksel olarak ortaya koyulabilmesi hedeflenmiştir. Bu doğrultuda çalışma; giriş bölümünün ardından literatür taraması, veri seti ve kullanılan metotların teorik olarak bahsedildiği veri seti ve yöntem bölümü, kurulan modellerin çıktılarından oluşan grafik ve istatistiksel tabloların sunulduğu bulgular ve tartışma bölümü ve son olarak bulguların birlikte değerlendirilerek literatüre eklendiği sonuç bölümü olmak üzere beş ana kısımdan oluşmaktadır.

Bu kısımda araştırma konusundaki literatürdeki çalışmalar incelenerek içerikleri ve farklılıkları karşılaştırılmıştır.

2.1. Hava Kirliliği ve Halk Sağlığı İlişkisi

Hava kirliliği, günümüzde hem çevresel sürdürülebilirlik hem de insan sağlığı açısından küresel ölçekte önemli sorunlardan biri olarak kabul edilmektedir. Sanayileşme, kentleşme, nüfus artışı, fosil yakıt kullanımı ve motorlu taşıt yoğunluğu gibi faktörler hava kalitesinin bozulmasına neden olmaktadır. Ve bu durum bireylerin sağlık risklerini artırmaktadır. Dünya Sağlık Örgütü'ne göre hava kirliliği her yıl milyonlarca insanın erken ölümüne neden olmakla birlikte özellikle solunum sistemi ile kardiyovasküler hastalıkların görülme sıklığını artırmaktadır.

Literatürde hava kirliliğinin insan sağlığı üzerindeki etkilerini inceleyen çalışmaların büyük bir çoğunluğu daha çok $PM_{2.5}$, PM_{10} , NO_2 ve SO_2 gibi kirlleticilere odaklanmaktadır. $PM_{2.5}$ olarak bilinen ince partikül maddelerin akciğerlerin derin bölgelerine kadar ulaşabilmesi, bu kirleticiyi sağlık açısından en tehlikeli kirleticilerden biri olarak konumlandırmaktadır. Bunun yanında meteorolojik koşullar, nem oranı, sıcaklık ve rüzgar hızı gibi değişkenlerin de hava kirliliğini etkilediği araştırılmıştır.

Son yıllarda geleneksel istatistiksel yöntemlerin yanı sıra makine öğrenmesi ve derin öğrenme algoritmalarının hava kirliliği ile ilgili çalışmalarda yaygın şekilde kullanılmaya başlandığı görülmektedir. Random Forest, XGBoost, Gradient Boosting, LSTM, Lasso ve lojistik regresyon gibi yöntemler sayesinde hava kirliliği seviyeleri daha yüksek doğruluk oranlarıyla tahmin edilebilmekte ve sağlık üzerindeki etkiler daha detaylı analiz edilebilmektedir. Bu doğrultuda literatürde yer alan çalışmalar incelendiğinde, araştırmaların genel olarak üç temel alanda yoğunlaştığı görülmektedir:

1. Hava kalitesi seviyelerinin tahmin edilmesi,
2. Hava kirliliğinin sağlık üzerindeki etkilerinin incelenmesi,
3. Makine öğrenmesi algoritmalarının performans karşılaştırmaları.

Temirbekov vd., (2023) tarafından gerçekleştirilen çalışmada Kazakistan'ın Almatı şehrindeki hava kirliliği ile solunum yolu hastalıkları arasındaki ilişki incelenmiştir. Araştırmada 2017–2022 yılları arasındaki hava kirliliği verileri kullanılmış ve askıda partikül maddelerin halk sağlığı üzerindeki etkilerine odaklanılmıştır. Çalışmada Random Forest algoritmasına dayalı modeller geliştirilmiş ve hava kirliticilerinin sağlık riskleri üzerindeki etkileri analiz edilmiştir. Bu yöntem, doğrusal olmayan ilişkilerin analiz edilmesinde avantajlar sağlamıştır. Hava kirliticilerinin etkilerine ek olarak COVID-19 enfeksiyonu ile solunum yolu hastalıkları arasındaki korelasyon da değerlendirilmiştir. Araştırma sonuçlarına göre, $PM_{2.5}$ seviyelerindeki artışın solunum yolu hastalıklarında da artışlara neden olduğunu göstermektedir.

Di vd., (2017) tarafından gerçekleştirilen araştırmada Amerika Birleşik Devletleri'nde yaşayan 60 milyondan fazla Medicare kullanıcısının verileri analiz edilmiştir. Bu çalışma, geniş örneklem büyüklüğü nedeniyle literatürde önemli bir yere sahiptir. Çalışmada $PM_{2.5}$ ve ozon maruziyeti ile ölüm oranları arasındaki ilişki incelenmiştir. Araştırmadan elde edilen sonuçlar, düşük seviyelerdeki $PM_{2.5}$ maruziyetinin bile ölüm oranlarında artışa neden olabileceği göstermektedir.

Liao vd., (2020) tarafından gerçekleştirilen çalışmada $PM_{2.5}$ maruziyetinin yaşlı bireylerdeki etkileri incelenmiştir. Çalışmaya 65 yaş üzerindeki 20.606 birey dahil edilmiş olup hava kirliliğinin fiziksel güç kaybı, hareket kabiliyetinde azalma ve yaşam kalitesinde düşüş ile ilişkili olduğu sınıanmıştır. Araştırmacılar, uzun süreli $PM_{2.5}$ maruziyetinin yaşlı bireyler üzerinde ciddi sağlık riskleri oluşturduğunu ifade etmiştir.

Kelly ve Fussell (2015)'in yürüttüğü çalışmada şehir içinde yaşayan insanların büyük çoğunluğunun uluslararası standarttan daha kötü kalitede hava soluduğu belirtilmiştir. Bunun yanında son 10 senedeki verilerle $PM_{2.5}$ kirleticisinin halk sağlığı üzerinde önemli derecede etkili ve hastalıkların tetikleyicisi olduğu belirlenmiştir.

Bir başka çalışma olan Harvard Altı Şehir Araştırması'nda ise uzun süreli $PM_{2.5}$ maruziyetinin solunum yolu vakalarını ve kardiyovasküler vakaları tetiklediği tespit edilmiştir. Bunun yanında çalışmada bu kirleticinin uzun zamanda insan ömrü üzerinde de etkilerinin olduğu bulunmuştur (Dockery vd., 1993).

Yine Kelly ve Fussell (2011) taraflarınca yürütülen bir başka çalışmada ise solunum esnasında vücuda giren ince partikül maddelerinin akciğer alveollerine kadar ilerleyerek enfeksiyonlara sebebiyet verdiği saptanmıştır. Belirtilen enfeksiyonlardan bazıları astım, kronik bronşit ve damar tıkanıklığı olarak belirtilmiştir.

Bu çalışmalar birlikte incelendiğinde, hava kirliliğinin yalnızca kısa dönemli sağlık sorunlarına değil, uzun dönemli sağlık problemlerine de neden olabileceği görülmektedir.

Tablo 1. Hava Kirliliği ve Halk Sağlığı İlişkisi Çalışmaları Tablosu

Yazar ve Yılı	Yöntem	Bulgular
Temirbekov vd., (2023)	Random Forest	$PM_{2.5}$ seviyesindeki artış solunum yolu hastalıklarını artırmaktadır.
Di vd., (2017)	Büyük Veri Analizi ve İstatistiksel Modelleme	Düşük seviyede $PM_{2.5}$ maruziyeti bile ölüm oranında artışa sebep olmaktadır.
Liao vd., (2020)	Kohort Analizi ve Sağlık Taraması	Uzun süreli $PM_{2.5}$ maruziyetinin, yaşlılarda fiziksel güç kaybı, hareket kısıtlılığı ve yaşam kalitesinde ciddi düşüşe sebep olduğu gözlemlenmiştir.

Kelly ve Fussel, (2015)	Sistemik Literatür Derlemesi ve Durum Analizi	$PM_{2.5}$ kirleticisinin hastalık çeşitliliğini artırdığı belirlenmiştir.
Dockery vd., (1993)	Kohort Analizi ve Regresyon Modelleri	$PM_{2.5}$ maddesinin solunum yolu ve kardiyovasküler vakaları tetiklediği tespit edilmiştir.
Kelly ve Fussel, (2011)	Kohort Analizi ve Zaman Serisi Analizleri	İnce partikül maddelerin solunumla vücuda alınıp çeşitli enfeksiyonlara sebep oldukları bulunmuştur.

2.2. Hava Kalitesi Tahmini ve Makine Öğrenmesi Yaklaşımları

Geleneksel regresyon yöntemleri değişkenler arası doğrusal ilişkileri açıklamada etkili sonuçlar verse de hava kirliliği gibi çok değişkenli ve her zaman doğrusal olmayan problemlerde yetersiz kalabilmektedir. Bu nedenle son yıllarda literatürde daha gelişmiş algoritmaların kullanıldığı görülmektedir.

Kim vd., (2022) tarafından gerçekleştirilen çalışmada Güney Kore'nin Seul kentindeki $PM_{2.5}$ seviyeleri tahmin edilmiştir. Araştırmada meteorolojik değişkenler ve hava kirliliği verileri kullanılarak derin öğrenme tabanlı modeller geliştirilmiş olup LSTM ağları ile istatistiksel modeller karşılaştırılarak derin öğrenme yöntemlerinin daha yüksek doğruluk sağladığı sonucuna ulaşılmıştır. Araştırmacılar derin öğrenme yöntemlerinin yanında zaman serisi bileşenlerinin de modele eklenmesinin modelin tahmin başarısını artırdığını belirtmiştir.

Liao vd., (2024) tarafından gerçekleştirilen çalışmada ise lojistik regresyon modeli kullanılarak Güney Şili'deki $PM_{2.5}$ ve PM_{10} seviyelerindeki kritik eşiklerin tahmini amaçlanmıştır. Araştırmada özellikle soğuk hava koşulları ve konutlarda odun kullanımının hava kirliliği üzerindeki etkileri incelenmiştir. Sonuçlara göre belirli meteorolojik koşullarda hava kirliliği seviyelerinin önemli ölçüde arttığı görülmüştür.

Bunun yanında Rajesh vd., (2025) tarafından yürütülen ve Scientific Reports dergisinde yayımlanan çalışmada kentsel, kırsal ve endüstriyel bölgelerde hava kalitesinin gerçek zamanlı olarak değerlendirilmesi amaçlanmıştır. Çalışmada Random Forest, Gradient Boosting, XGBoost ve LSTM algoritmaları birlikte kullanılmıştır. Araştırmanın en önemli yönü, yalnızca hava kalitesinin kötü olduğunu belirtmek yerine, sağlık risklerini önceden tahmin etmeye odaklanmasıdır.

Literatürde doğrudan sınıflandırma problemlerine odaklanan çalışmalar da mevcuttur. Bu çalışmalarda genellikle AQI değerlerinin belirli kategorilere ayrılmasıyla çeşitli makine öğrenmesi algoritmaları kullanılmaktadır.

Pathak vd., (2024) taraflarınca yürütülen ve IEEE veri tabanında yer alan çalışmada Naive Bayes ve Decision Tree algoritmaları kullanılarak hava kalitesi sınıflandırması gerçekleştirilmiştir. Araştırmada hava kalitesi seviyeleri “iyi”,

“orta”, “sağlıklı” ve “tehlikeli” gibi kategorilere ayrılmış olup çalışma sonucunda Decision Tree algoritmasının daha başarılı sonuçlar verdiği belirtilmiştir.

Benzer şekilde Gore vd., (2017) tarafından yürütülen çalışmada ise AQI değerleri üzerinden “Hassas Gruplar İçin Sağlıklı” sınıfının tahmin edilmesi amaçlanmıştır. Araştırmacılar hava kalitesi indeksine bağlı olarak risk sınıfları oluşturmuş ve belirli eşik değerlerin aşılması durumunda sağlık risklerinin arttığını belirtmiştir.

Bu çalışmalar incelendiğinde, makine öğrenmesi algoritmalarının hava kalitesi tahmini konusunda geleneksel yöntemlere göre daha başarılı sonuçlar verdiği görülmektedir. Özellikle Random Forest ve XGBoost gibi algoritmalar değişken önem sıralamalarını belirleme konusunda avantaj sağlarken, LSTM ağları zaman serisi verilerinin analizinde daha başarılı sonuçlar sunmaktadır.

Tablo 2. Hava Kalitesi Tahmini ve Makine Öğrenmesi Çalışmaları Tablosu

Yazar ve Yılı	Yöntem	Bulgular
Kim vd., (2022)	LSTM ve İstatistiksel Modeller	Derin öğrenme modelleri $PM_{2.5}$ tahmininde yüksek doğruluk sağlamaktadır.
Liao vd., (2024)	Lojistik Regresyon	Odun kullanımı ve meteorolojik koşullar hava kirlleticilerinin eşik değerini etkilemektedir.
Rajesh vd., (2025)	Random Forest, Gradient Boosting, XGBoost, LSTM	Hava kalitesi verileriyle sağlık riskleri %93 doğrulukla tahmin edilmektedir.
Pathak vd., (2024)	Naive Bayes ve Karar Ağaçları	Hava kalitesi seviyeleri sınıflandırılmıştır. Karar Ağaçları algoritmasının Naive Bayes modeline göre daha yüksek sınıflandırma başarısı gösterdiği tespit edilmiştir.
Gore vd., (2017)	Veri Madenciliği Sınıflandırma Teknikleri ve Eşik Değer Analizi	AQI değerlerine bağlı “Hassas Gruplar İçin Sağlıklı” sınıfı tahmin edilmiştir ve belirlenen kritik eşik değerlerin aşıldığı durumlarda halk sağlığına yönelik riskler anlamlı derecede arttığı saptanmıştır.

2.3. Çalışmanın Katkısı

Literatürde yer alan çalışmalar birlikte tarandığında, araştırmaların büyük çoğunluğu hava kirlleticilerinin sağlık üzerindeki etkilerinden ziyade hava kalitesi tahmini veya hava kalitesinin sınıflandırılması üzerine yoğunlaşmıştır. Hava kirliliğinin sağlık etkisini inceleyen çalışmalarda, hava kirlleticilerinin sağlık üzerindeki etkilerinin nicel tahmini sınırlı düzeyde ele alınmıştır. Meteorolojik koşulların etkilerinin (nem, rüzgar hızı, sıcaklık vb.) ayrı modellenmesi çalışmaları yeterince yapılmamıştır. Değişken önem düzeyleri çoğu çalışmada detaylı olarak raporlanmamıştır.

Bu arařtırmada, literatürdeki çalıřmalardan farklı olarak hava kirleticilerinin saėlık üzerindeki etkileri makine öğrenmesi algoritmaları (Lineer Regresyon, Random Forest, Lasso, Ridge, SVR, K-NN ve XGBoost) kullanılarak analiz edilmektedir. Bu çalıřmanın özgünlüėü sadece model çeřitliliėiyle sınırlı kalmayıp, açıklama gücü en yüksek olan iki model logaritmik dönüşüm ve standardizasyon işlemlerinden geçirilerek yeniden model kurulmuřtur ve performansları sınanmıřtır. Ayrıca modeller kurulduktan sonra bütün deėiřkenlerin önem düzeyleri incelenmiřtir. En iyi iki modelde hava kirleticilerinin solunum yolu hastalıkları ve kalp-damar hastalıklarının üzerindeki etkileri de incelenmiřtir. Hava kirleticilerinin azaltıldıėı senaryo, arttıėı senaryo ve meteorolojik deėiřimler üzerinden ileriye donuk tahmin yapılmıřtır.

3

VERİ SETİ VE YÖNTEM

Bu çalışmada, hava kirleticilerinin sağlık üzerindeki etkilerini tahmin etmek için makine öğrenmesi yöntemleri kullanılmıştır. Bu süreçte veriler hazırlanmıştır, değişkenler seçilmiştir, modeller geliştirilmiştir ve modellerin ne kadar iyi çalıştığı sınanmıştır. Çalışmada, hava kirleticilerini ve halk sağlığını incelemek için R dilinden yararlanılmıştır.

3.1. Veri Seti

Bu çalışmada, Kaggle'da bulunan El Kharoua (2024) tarafınca yayınlanan "Air Quality Health Impact Dataset" kullanılmıştır. Bu veri seti; hava kalitesi göstergeleri, hava durumu değişkenleri ve sağlık etkisi değişkenleri içermektedir. Üzerinde çalışılan bu veri setinde 5.811 gözlem değeri bulunmaktadır. Çalışmada, bağımsız değişkenler olarak hava kirleticileri, meteorolojik faktörler ve bazı sağlık göstergeleri kullanılmıştır. Veri setinin içindeki Sağlık Etki Puanı değişkeni ise bağımlı değişken olmuştur. Veri setindeki değişkenlere ilişkin detaylar aşağıdaki gibidir:

Tablo 3. Veri Setindeki Değişkenler Tablosu

Hava Kirleticileri	Meteorolojik Koşullar	Sağlık Göstergeleri	Bağımlı Değişkenler
AQI	Sıcaklık	Solunum Yolu Vakaları	Sağlık Etki Puanı
PM ₁₀	Nem	Kardiyovasküler Vakalar	Sağlık Etki Sınıfı
PM _{2.5}	Rüzgar Hızı	Hastaneye Yatışlar	
NO ₂			
SO ₂			
O ₃			

3.1.2. Hava Kirleticileri

3.1.2.1. Hava Kalitesi İndeksi (AQI)

Çevre, Şehircilik ve İklim Değişikliği Bakanlığına (CSB, t.y.) göre, solunan hava kalitesinin raporlanması ve analiz edilebilmesi için tutulan bir göstergedir.

3.1.2.2. PM₁₀ ve PM_{2.5}

Hava kirleticilerinden PM₁₀ çapı 10 mikrometrenin altındaki kaba partikül maddelerin yoğunluğuyken, PM_{2.5} ise çapı 2.5 mikrometrenin altındaki ince partikül maddelerin yoğunluğudur (Öztürk, 2021).

3.1.2.3. NO₂

Bir azot ve iki oksijen atomunun birleşmesiyle meydana gelen azot dioksit (NO_2), Amerikan Akciğer Derneği (ALA, 2023) tarafından majör bir atmosferik kirletici olarak kabul edilmektedir. İlgili kurum; kömür, petrol, doğal gaz veya dizel yakıt gibi fosil kaynakların yüksek sıcaklık altında yakılma süreçlerinin NO_2 oluşumuna sebebiyet verdiğini raporlamaktadır. Gaz formundaki bu bileşiğin suda çözünürlük kapasitesinin düşük olması, solunum yoluyla maruz kalınan NO_2 gazının büyük bir bölümünün doğrudan periferik hava yollarına ve derin akciğer dokularına nüfuz etmesine zemin hazırlamaktadır. Solunumu gerçekleştirilen NO_2 , doğrudan kendi moleküler yapısıyla ya da sekonder bir reaksiyon ürünü şeklinde doku absorpsiyonu ve kan-gaz bariyeri üzerinden dolaşım sistemine katılarak organizmada sistemik olumsuz etkilere yol açabilmektedir (Mainka ve Žak, 2022).

3.1.2.4. SO_2

Kömür ve petrol gibi fosil yakıtların yanma süreçleri neticesinde açığa çıkan kükürt dioksit (SO_2) keskin kokusuyla ayırt edilen, asit yağmurları ile çeşitli solunum yolu anomalilerine yol açan bir gaz olup, atmosferdeki konsantrasyonu ppb birimiyle ölçülmektedir. Çevre, Şehircilik ve İklim Değişikliği Bakanlığı (2024) verilerine göre (SO_2) gazı, insan organizması üzerinde doğrudan toksik (zehirleyici) etkilere sahip olmakla birlikte primer olarak solunum sistemi fonksiyonlarını sekteye uğratmaktadır. Ayrıca bu bileşiğin atmosferik reaksiyonlar sonucunda sülfürik asit ve sülfat formlarına dönüşmesi, halk sağlığını dolaylı bir kulvarda da tehdit etmesine zemin hazırlamaktadır.

3.1.2.5. O_3

Yeryüzünden yaklaşık 15 ila 35 kilometre yükseklikte yer alan stratosfer katmanında yoğunlaşarak ozon tabakasını meydana getirmesi, ozon (O_3) azını küresel ekosistem için kritik bir bileşen kılmaktadır. Söz konusu katman, güneşten yayılan zararlı ultraviyole (UV) radyasyonun büyük bir kısmını absorbe ederek yeryüzündeki biyolojik hayat için koruyucu bir kalkan vazifesi görmektedir (ESA Elektronik, t.y.). Ancak stratosferdeki bu hayati ve koruyucu rolünün aksine O_3 troposferde (yeryüzüne en yakın alt atmosfer tabakasında) kümelenmesi durumunda kuvvetli bir oksidan ve ikincil bir hava kirletici olarak işlev görerek canlı sağlığı üzerinde ciddi tehditler barındırmaktadır. Bu doğrultuda yürütülen çalışmada, yer seviyesindeki ozon O_3 konsantrasyonunun insan sağlığı —özellikle pulmoner sistem fonksiyonları— üzerindeki olumsuz yansımalarını ampirik olarak değerlendirmek ve bu kirleticinin sağlık etki puanı üzerindeki marjinal etkilerini incelemek amacıyla ilgili değişken modele bağımsız bir tahminci olarak dahil edilmiştir.

3.1.3. Meteorolojik Koşullar

3.1.3.1. Sıcaklık (Temperature)

El Kharoua (2024) tarafından literatüre sunulan veri setinde, meteorolojik parametreler arasında yer alan hava sıcaklığı verileri; ölçümün yapıldığı zaman dilimi ve ilgili coğrafi bölge esas alınarak santigrat derece ($^{\circ}\text{C}$) birimiyle kaydedilmiştir.

3.1.3.2. Nem (Humidity)

İstatistiki analizlerde değerlendirmeye alınan nem parametresi, atmosfer kütlesi içinde barınan güncel su buharı miktarını temsil etmekte olup yüzde (%) birimi ekseninde hesaplanarak veri setine aktarılmıştır (El Kharoua, 2024).

3.1.3.3. Rüzgar Hızı (WindSpeed)

Hava kalitesi dinamikleri üzerinde doğrudan belirleyici olan, kirletici bileşenlerin atmosferdeki dağılımı ile taşınım süreçlerinde kritik bir rol üstlenen rüzgar hızı değişkeni, saniyede metre (m/s) birimi ekseninde kaydedilmiştir (El Kharoua, 2024).

3.1.4. Sağlık Göstergeleri

3.1.4.1. Solunum Yolu Vakaları (RespiratoryCases)

Söz konusu değişken, veri setinde analiz edilen ilgili zaman kesiti ve coğrafi alanda raporlanan ya da sağlık kuruluşlarına müracaat eden astım ve bronşit gibi pulmoner hastalıkların toplam vaka insidansını temsil etmektedir (El Kharoua, 2024).

3.1.4.2. Kardiyovasküler Vakalar (CardiovascularCases)

Hava kirliliği parametrelerine bağlı olarak gelişen akut koroner sendromlar, disritmiler ve kalp yetmezliği gibi kardiyovasküler hastalıklar neticesinde sağlık kuruluşlarına müracaat eden klinik olgu sayısı, araştırmada bağımlı bir değişken olarak kayıt altına alınmıştır (El Kharoua, 2024).

3.1.4.3. Hastaneye Yatışlar (HospitalAdmissions)

Hava kirliliğinin tetiklediği patolojilerin klinik seyrini ve sağlık altyapısı üzerindeki doğrudan iş yükünü belirlemek adına modele entegre edilen bu değişken; pulmoner veya kardiyovasküler hastalıklar öncelikli olmak üzere, atmosferik kirliliğe bağlı semptomlar neticesinde yataklı tedavi servislerine ya da yoğun bakım ünitelerine yatışı yapılan kümülatif hasta sayısını temsil etmektedir (El Kharoua, 2024).

3.1.5. Bağımlı Değişkenler

3.1.5.1. Sağlık Etki Puanı (HealthImpactScore)

Atmosferik kirlilik parametreleri, anlık meteorolojik dinamikler ve ilgili coğrafi alanda saptanan morbidite (hastalanma) oranlarının entegrasyonu ile hesaplanan bu değişken, 0 ile 100 arasında skalalandırılmış bir indeks değerine tekabül etmektedir (El Kharoua, 2024). Söz konusu indeks değeri, ele alınan çevresel ve meteorolojik faktörlerin toplum sağlığı üzerindeki kümülatif ve doğrudan negatif yansımalarını kantitatif (nicel) olarak ortaya koymaktadır (El Kharoua, 2024).

3.1.5.2. Sağlık Etki Sınıfı (HealthImpactClass)

Söz konusu öznitelik, sağlık etki puanı esas alınarak yapılandırılmış kategorik bir değişkendir (El Kharoua, 2024). Modelin hedef (bağımlı) değişkeni olan sağlık etki puanı ile bu parametre arasında yüksek düzeyde korelasyon (eş doğrusal bağıntı) bulunması ve bu durumun tahmin sonuçlarında yanlılığa yol açma riski taşıması nedeniyle, ilgili değişken veri setinden dışlanarak analizler yürütülmüştür.

3.2. Tanımlayıcı İstatistikler

3.2.1. Hava Kirleticileri

Hava kalitesi parametrelerine ilişkin genel tanımlayıcı istatistikler Tablo --- da sunulmuştur. Veri setinde bulunan tüm hava kirleticilerine ait 5811 gözlem değeri bulunmaktadır.

Merkezi eğilim ölçüleri incelendiğinde, Hava Kalitesi İndeksi (AQI) değerlerinin ortalaması 248.44 ve medyanı 249.13 olarak belirlenmiştir. Standart sapma değerinin yüksekliği ve verilerin minimum 0.01 ile maksimum 499.86 gibi geniş bir aralıkta dağılım göstermesi, ölçüm dönemi boyunca hava kalitesinde yüksek düzeyde varyasyon ve dalgalanmalar yaşandığını ortaya koymaktadır.

Veri setinin normallik ve simetri özelliklerini değerlendirmek amacıyla çarpıklık ve basıklık katsayıları analiz edilmiştir. Parametrelerin çarpıklık katsayıları incelendiğinde; PM_{2.5} değerinin tam simetrik, NO₂ değerinin hafif sola çarpık, diğer tüm kirleticilerin ise 0.01 ile 0.03 arasında sıfıra oldukça yakın değerlerle hafif sağa çarpık bir eğilim sergilediği görülmektedir. Ortalama ve medyan değerlerinin birbirine yakınlığı da bu simetrik yapıyı doğrulamaktadır. Öte yandan, tüm parametrelere ait basıklık katsayılarının negatif yönlü olduğu tespit edilmiştir. İstatistiksel literatürde basıklık değerinin sıfırdan küçük olması, dağılımın basık bir yapıya sahip olduğunu göstermektedir. Bu durum, ölçüm değerlerinin normal dağılıma kıyasla ortalama etrafında sivri bir yığılma yapmak yerine, daha geniş ve homojen bir alana yayıldığına işaret etmektedir.

Tablo 4. Hava Kirleticilerinin Tanımlayıcı İstatistikleri

	AQI	PM10	PM2.5	NO2	SO2	O3
Gözlem Sayısı	5811	5811	5811	5811	5811	5811
Ortalama	248.44	148.66	100.22	102.29	49.46	149.31
Medyan	249.13	147.64	100.51	102.99	49.53	149.56
Minimum	0.01	0.02	0.03	0.01	0.01	0.00
Maksimum	499.86	299.90	199.99	199.98	99.97	299.94
Std. Sapma	144.78	85.70	58.10	57.71	28.53	86.53
Çarpıklık	0.01	0.02	0.00	-0.05	0.03	0.01
Basıklık	-1.21	-1.18	-1.21	-1.19	-1.17	-1.21

3.2.2. Meteorolojik Koşullar

Araştırma modelinde yer alan meteorolojik bağımsız değişkenlere ait genel tanımlayıcı istatistiksel göstergeler Tablo 5'te sunulmuştur.

Merkezi eğilim ve dağılım ölçüleri incelendiğinde; sıcaklık değişkeninin ortalaması 14.97 ve medyanı 14.94 olarak tespit edilmiştir. Sıcaklık değerlerinin -9.99 ile 39.96 derece arasında geniş bir aralıkta değişim göstermesi, veri setinin farklı mevsimsel dönemleri kapsayan heterojen bir yapıya sahip olduğunu göstermektedir. Nem parametresi incelendiğinde, ortalama nem oranı %54.78 olarak hesaplanmış olup, minimum %10 ile maksimum %100 uç değerleri arasında dağılmaktadır. Rüzgar hızı ise ortalama 9.99 m/s seviyesinde gerçekleşmiş ve 0 ile 20.00 m/s arasındaki skalada ölçülmüştür.

Değişkenlerin çarpıklık katsayıları incelendiğinde; sıcaklık parametresinin tam simetrik bir dağılım sergilediği, nem değerinin sıfıra oldukça yakın çok hafif sağa çarpık ve rüzgar hızının ise çok hafif sola çarpık bir eğilimde olduğu görülmektedir.

BASIKLIK KATSAYILARI İNCELENDİĞİNDE İSE; TÜM DEĞİŞKENLERİN NEGATİF YÖNLÜ OLDUĞU TESPİT EDİLMİŞTİR. BASIKLIK KATSAYISI SIFIRDAN KÜÇÜK OLDUĞU İÇİN DAĞILIMIN BASIK OLDUĞU GÖRÜLMEKTEDİR.

Tablo 5. Meteorolojik Koşulların Tanımlayıcı İstatistikleri

	Sıcaklık	Nem	Rüzgar hızı
Gözlem Sayısı	5811	5811	5811
Ortalama	14.97	54.78	9.99
Medyan	14.94	54.54	10.05
Minimum	-9.99	10.00	0.00
Maksimum	39.96	100.00	20.00
Std. Sapma	14.48	26.02	5.78
Çarpıklık	0.00	0.02	-0.01
Basıklık	-1.20	-1.21	-1.21

3.2.3. Sağlık Göstergeleri

İncelenen sağlık göstergelerine ilişkin genel tanımlayıcı istatistiksel göstergeler Tablo 6’da sunulmuştur.

Merkezi eğilim ve dağılım ölçütleri incelendiğinde; solunum yolu vakaları değişkeninin ortalaması 9.97 olarak bulunmuş ve günlük vaka sayısının 1 ile 23 arasında değiştiği görülmektedir. Kardiyovasküler vakaların günlük ortalaması 4.99 olarak hesaplanmış olup, minimum 0 ile maksimum 14 değerleri arasında dağılım göstermektedir. Hastaneye yatışlar parametresi değerlendirildiğinde ise günlük ortalama yatış sayısının 2 olduğu ve vaka sayılarının 0 ile 12 uç değerleri arasında değiştiği görülmektedir.


Değişkenlerin çarpıklık katsayıları incelendiğinde; katsayıların sıfırdan büyük olması, tüm sağlık parametrelerinin sağa çarpık bir dağılım eğilimi sergilediğini ortaya koymaktadır. Özellikle hastane yatışlarındaki 0.72’lik çarpıklık değeri, diğer değişkenlere kıyasla sağa kuyruklu yapının daha belirgin olduğunu anlatmaktadır.

Basıklık katsayıları incelendiğinde ise; değişkenlerin basıklık katsayılarının sıfırdan büyük olması sebebiyle dağılımlarının sivri olduğu görülmektedir. Bu durum, sağlık verilerinin normal dağılım eğrisine kıyasla ortalama etrafında daha

yüksek bir yığılma oluşturduğunu ve kuyrukların daha kalın olduğunu kanıtlamaktadır.

Tablo 6. Sağlık Göstergelerinin Tanımlayıcı İstatistikleri

	Solunum Yolu Vakaları	Kardiyovasküler Vakalar	Hastane Yatışları
Gözlem Sayısı	5811	5811	5811
Ortalama	9.97	4.99	2.00
Medyan	10.00	5.00	2.00
Minimum	1.00	0.00	0.00
Maksimum	23.00	14.00	12.00
Std. Sapma	3.13	2.22	1.40
Çarpıklık	0.26	0.44	0.72
Basıklık	0.09	0.23	0.77



Şekil 1. Korelasyon Matrisi

(1)

Şekil 1 değişkenlere ait korelasyon matrisini göstermektedir. Korelasyon matrisi incelendiğinde, değişkenlerin büyük bir kısmının birbirleriyle oldukça zayıf bir doğrusal ilişki sergilediği dikkat çekmektedir. Köşegen üzerinde yer alan koyu lacivert hücreler, her değişkenin kendisiyle olan doğrusal ilişkisini ($\rho = 1$) göstermektedir. AQI ile Sağlık Etki Puanı değişkenleri arasında pozitif yönlü ve orta-güçlü düzeyde bir doğrusal ilişki tespit edilmiştir. Benzer şekilde, partikül maddeler ($PM_{2.5}$, PM_{10}) ve gaz kirleticiler (NO_2 , O_3) ile Sağlık Etki Puanı arasında da pozitif yönlü, zayıf-orta düzeyde doğrusal ilişkiler görülmektedir. Buna karşın, Solunum Yolu Vakaları, Kardiyovasküler Vakalar ve Hastane Yatışları gibi doğrudan klinik vaka sayılarını içeren değişkenlerin, hava kirleticileriyle ve meteorolojik faktörlerle olan doğrusal korelasyonlarının sıfıra oldukça yakın olduğu görülmektedir.

3.3. Yöntem

3.3.1. Makine Öğrenmesi

Makine öğrenmesi, yapay zekânın önemli alt alanlarından biridir. Bu yaklaşım, sistemlerin verilerden öğrenmesine dayanmakta ve elde edilen bilgiler doğrultusunda tahminlerde bulunmasına, verileri belirli sınıflara ayırmasına ve değişkenler arasındaki ilişkileri ortaya koymasına olanak sağlamaktadır. İstatistiksel modeller ve optimizasyon tekniklerinden yararlanan makine öğrenmesi, verilerdeki örüntüleri tespit ederek çeşitli problemlerin çözümünde etkili sonuçlar sunmaktadır. Bu sayede sistemler, açık şekilde programlanmadan deneyimlerden öğrenebilmekte ve karar verme süreçlerinde daha başarılı performans gösterebilmektedir (Coşar, 2023).

3.3.1.1. Klasik Çoklu Doğrusal Regresyon Modeli

Birden çok bağımsız değişkenin tek bir bağımlı değişken üzerindeki doğrusal etkisini ölçümlemek ve tahmin etmek amacıyla literatürde en yaygın kullanılan klasik yaklaşım Klasik Çoklu Doğrusal Regresyon (KÇDR) modelidir. Hava kirliliği verilerinin halk sağlığı göstergeleri üzerindeki doğrusal etkilerini ortaya koymak adına kurulan doğrusal regresyon modeli, n gözlem ve k bağımsız değişken için Eşitlik (1)'deki gibi tanımlanır:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_k X_{ik} + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (1)$$

Burada;

Y_i : i . Gözleme ait bağımlı değişken değerini (Halk sağlığı sonucu),

X_{ij} : i . Gözleme ait j . bağımsız değişken değerini (Halk sağlığı sonucu),

$\beta_0, \beta_1, \dots, \beta_k$: Modelin tahmin edilmesi gereken bilinmeyen parametrelerini (regresyon katsayıları),

ε_i : i . Gözleme ait rasgele hata terimini ifade etmektedir.

Klasik doğrusal regresyon modelinin parametrelerinin sapmasız ve etkin özelliklere sahip olabilmesi belirli temel varsayımların karşılanmasına bağlıdır. Bu doğrultuda hata terimleri (ε) vektörüne ve tasarım matrisine ilişkin standart varsayımlar matris formunda şu şekilde özetlenebilir: (Felek, 2025)

1. **Sıfır Hata Ortalaması:** Belirlenen bağımsız değişken matrisine bağlı olarak, hata serisinin matematiksel beklentisi sıfıra eşittir: $E(\varepsilon|X) = 0$

2. *Sabit Varyans (Homoscedasticity)*: Hata terimlerinin her bir gözlem için sergilediği varyans sabittir ve değişmeyen bir dağılım gösterir: $Var(\varepsilon) = E(\varepsilon\varepsilon') = \sigma^2 I$ (Burada I , $n \times n$ boyutlu birim matristir.)
3. *Otokorelasyon Olmaması*: Farklı gözlemlere ait hata terimleri arasında herhangi bir kovaryans ya da doğrusal ilişki söz konusu değildir: $Cov(\varepsilon_i, \varepsilon_j) = 0 (\forall i \neq j)$
4. *Çoklu Doğrusal Bağlantı Olmaması*: Tasarım matrisini oluşturan vektörler arasında tam bir doğrusal bağımlılık yoktur, yani $rank(X) = k + 1 < n$ olup $X'X$ matrisi tersi alınabilir (non-singular) bir matristir.

Bu varsayımlar altında, gözlenen değerler ile modelden elde edilen tahmin değerleri arasındaki hata kareler toplamını minimum yapmayı amaçlayan En Küçük Kareler (EKK) yöntemiyle parametre vektörü (β) eşitlik (2)'deki matris işlemiyle tahmin edilmektedir. (Felek, 2025):

$$\beta = (X^T X)^{-1} X^T Y \quad (2)$$

3.3.1.2. Rastgele Orman (Random Forest) Modeli

Birden çok bağımsız değişkenin tek bir bağımlı değişken üzerindeki doğrusal olmayan ve karmaşık etkilerini modellemek, yüksek boyutlu veri setlerinde doğru tahminler üretmek amacıyla literatürde en yaygın kullanılan toplu öğrenme (ensemble learning) yaklaşımı Rastgele Orman (Random Forest) algoritmasıdır. Hava kirliliği verilerinin halk sağlığı göstergeleri üzerindeki karmaşık, doğrusal olmayan ve etkileşimli tesirlerini ortaya koymak adına kurulan Rastgele Orman regresyon modeli, n gözlem ve p bağımsız değişken için Eşitlik (3)'deki gibi tanımlanmaktadır:

$$y_i = \frac{1}{B} \sum_{b=1}^B T_b(x_i; \theta_b), \quad i = 1, 2, \dots, n \quad (3)$$

Burada;

y_i : i . gözleme ait bağımlı değişkenin (Halk sağlığı sonucu) model tarafından üretilen nihai tahmin değerini,

x_i : i gözleme ait bağımsız değişken vektörünü,

B : Ormandaki toplam karar ağacı sayısını,

$T_b(x_i; \theta_b)$: θ_b rastgele parametre vektörüne göre eğitilmiş b . karar ağacının x_i girdisi için ürettiği bağımsız tahmini,

θ_b : b . ağacın eğitimi esnasında kullanılan bootstrap örneklemini ve her düğüm bölünmesinde rastgele seçilen bağımsız değişken alt kümesini ifade eden rastgelelik bileşenini temsil etmektedir.

Klasik doğrusal regresyon modellerinin aksine, Rastgele Orman algoritması parametrik olmayan bir yapıya sahip olduğundan hata terimlerine veya veri dağılımına ilişkin katı normallik varsayımlarına ihtiyaç duymamaktadır. Ancak modelin genelleştirme yeteneğinin (overfitting'i engelleme) yüksek ve varyansının düşük olabilmesi belirli yapısal koşullara ve hiper-parametrelere bağlıdır:

1. *Örneklem Çeşitliliği (Bagging/Bootstrap)*: Ormandaki her bir ağaç, orijinal veri setinden yerine koyarak seçme (bootstrap) yöntemiyle türetilen farklı alt veri setleri ile eğitilmelidir. Bu durum, ağaçlar arasındaki korelasyonu azaltarak modelin varyansını düşürmektedir.
2. *Değişken Rastgeleliği (Feature Subspace)*: Her karar ağacının düğüm bölünmesinde, mevcut p adet bağımsız değişken arasından rastgele m adet ($m < p$, genellikle regresyon için $m = p/3$) değişken seçilmeli ve en iyi bölünme bu alt küme üzerinden yapılmalıdır. Bu kural, baskın bağımsız değişkenlerin tüm ağaçları aynılaştırmasını engellemektedir.
3. *Ağaçların Bağımsızlığı*: Modelin kararlılığı için B (ağaç sayısı) yeterince büyük seçilmelidir. Ağaçlar birbirlerinden bağımsız ve paralel bir şekilde budama yapılmaksızın büyütülmektedir.
4. *Çoklu Doğrusal Bağlantı (Multicollinearity) Direnci*: Bağımsız değişkenler arasında yüksek korelasyon bulunması modelin tahmin başarısını klasik modeller gibi doğrudan bozmaz; ancak değişken önem derecelerinin yorumlanmasında yanlışlığa yol açabileceğinden dikkatle analiz edilmelidir.

3.3.1.3. Lasso Regresyon Modeli

Lasso regresyonu, temel yapısı itibarıyla klasik çoklu doğrusal regresyonun doğrusallık, eş varyanslılık ve otokorelasyon olmaması gibi temel varsayımlarını devralmaktadır. Buna karşın, katsayı tahmin sürecine entegre ettiği matematiksel kısıtlar sayesinde klasik modellerin yüksek boyutlu veri setlerinde karşılaştığı kısıtlılıkları aşmaktadır.

Modelde parametre vektörünün tahmini; hata kareler toplamını minimize ederken, eşzamanlı olarak katsayıların mutlak değerlerinin toplamını cezalandıran bir optimizasyon probleminin çözümüne dayanır. Bu doğrultuda, model karmaşıklığı ile yanlışlık-varyans dengesini kontrol eden ve negatif olmayan değerler alan λ (lambda) ayarlama parametresi altında, tahmin işlemi Eşitlik (4)'teki fonksiyonel süreçle gerçekleştirilmektedir:

$$\beta_{Lasso} = \arg \min \left\{ \sum_{i=1}^n (y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij})^2 + \lambda \sum_{j=1}^p |\beta_j| \right\} \quad (4)$$

Burada λ , modele uygulanacak büzülme ve ceza miktarını belirleyen hiper-parametredir. $\lambda = 0$ olduğunda uygulanan ceza sıfırlanır ve model klasik En Küçük Kareler (EKK) tahminine eşitlenir; λ değeri büyütüldükçe uygulanan ceza şiddetlenir, katsayılar sıfıra doğru büzülür ve nihayetinde modelde kalan değişken

sayısı azalarak daha yalın ve yorumlanabilir bir model elde edilir (Yüksel, 2026). Analiz süreçlerinde en uygun λ değerinin belirlenmesi amacıyla genellikle k - katlı çapraz doğrulama tekniğine başvurulmaktadır. Modelin yapısal ve ayırt edici özellikleri şu şekilde özetlenmektedir:

1. *L₁ Normu ile Katsayı Daraltma ve Değişken Seçimi*: Lasso, klasik En Küçük Kareler (EKK) regresyon fonksiyonuna bir L_1 -norm ($\sum_{j=1}^p |\beta_j|$) ceza terimi ekleyerek çalışmaktadır. Bu kısıt, katsayı tahminlerini kararlı bir biçimde sıfıra doğru küçülmeye zorlamakla birlikte etkisi zayıf olan veya model açıklayıcılığı düşük olan kirlilik parametrelerinin katsayıları tam olarak sıfıra ($\beta_j = 0$) eşitlemektedir. Katsayısı sıfıra indirgenen değişkenlerin model yapısından otomatik olarak dışlanması, algoritmanın hem bir tahmin aracı hem de doğal bir değişken seçimi yöntemi olarak eşzamanlı çalışmasını sağlamaktadır (Tibshirani, 1996; Yüksel, 2026).
2. *Çoklu Doğrusal Bağlantı ve Yüksek Boyut Direnci*: Bağımsız değişkenler arasında yüksek korelasyon (multicollinearity) bulunması durumunda klasik EKK yöntemi yüksek varyanslı ve sapan tahminler üretirken, Lasso bu değişkenlerden yalnızca birini seçip diğerlerini sıfırlayarak model varyansını düşürmektedir. Ayrıca KÇDR'nin aksine, değişken sayısının gözlem sayısından daha fazla olduğu ($p > n$) yüksek boyutlu veri mimarilerinde de etkin sonuçlar üretmektedir (Yüksel, 2026).
3. *Düşük Boyutlu Verilerde Performans*: Algoritma, değişken sayısının gözlem sayısından küçük olduğu ($p < n$) veri setlerinde de güçlü bir alt küme seçimi avantajı sunmaktadır. Literatürde, düşük boyutlu veri yapılarında Lasso'nun tahmin performansının Ridge regresyonuna kıyasla daha başarılı sonuçlar verebildiği gösterilmiştir (Yüksel, 2026). Bu yönüyle Lasso, hem Ridge regresyonunun varyans düşürme avantajını korumakta hem de alt küme seçimi yöntemlerinin yorumlanabilirlik gücünü bünyesinde barındırmaktadır.

3.3.1.4. Ridge Regresyon Modeli

Çoklu doğrusal bağlantı probleminin gerçekleşmemesi ve yüksek korelasyona sahip veri yapılarında normalden daha kararlı katsayı tahminleri yapmak amacıyla literatürde sıkça kullanılan bir düzenlileştirme yöntemidir. Temelleri Hoerl ve Kennard (1970) taraflarınca atılan bu yaklaşım, Klasik En Küçük Kareler (EKK) kayıp fonksiyonuna bir L_2 ceza terimi ekleyerek katsayıların aşırı büyüyen şişmesini kontrol altına almaktadır (Dianati, 2026). Ridge regresyon modelini amaç fonksiyonu L_2 - norm şeklinde (5)'deki gibi tanımlanmaktadır:

$$\min_{\beta \in \mathbb{R}^p} ||y - X\beta||_2^2 + \lambda ||\beta||_2^2 \quad (5)$$

y: Bağımlı değişken vektörünü,

X: Bağımsız değişken matrisini,

β : Tahmin edilmesi gereken parametre vektörünü,

$\|\beta\|_2^2 = \sum_{j=1}^p \beta_j^2$: Katsayıların karelerinin toplamını gösteren L_2 ceza operatörünü,

λ : Modelin karmaşıklığını denetleyen pozitif düzgünleştirme parametresini ortaya koymaktadır. (Modelde λ değerinin yükselmesiyle birlikte katsayılar asimptotik sıfıra yaklaşmaktadır ancak katsayılar hiçbir zaman tam anlamıyla sıfır olmamaktadır.)

Literatürde Ridge regresyon modeli, çoklu bağımsız değişken yapısının yarattığı karmaşıklığı yönetmede sıklıkla bir alternatif olarak görülmektedir. (Karaaslan vd., 2025: 12).

3.3.1.5. Destek Vektör Regresyon (SVR) Modeli

Doğrusal regresyon modellerinin yeterli olmadığı karmaşık veri yapılarında, açıklayıcı değişkenler ile hedef değişken arasındaki doğrusal olmayan ilişkileri yüksek doğrulukla modellemek için literatürde yaygın olarak tercih edilen makine öğrenmesi yöntemlerinden biridir. Vapnik (1995) tarafınca geliştirilen Destek Vektör Makinelerinin (SVR) regresyon problemlerine bir uzantısı olan bu yaklaşım, klasik en küçük kareler metodlarından farklı olarak, tahmin hatasını belirli bir ϵ eşik değeri sınırları içinde tutmayı hedefleyen optimizasyona dayanmaktadır. (Tiryaki, 2026). Bu modelde temel amaç, gözlem noktalarının ϵ eşik değerinin belirlenmesidir. Matematiksel formülasyonu doğrusal durumlar için eşitlik (6)'daki gibi tanımlanmaktadır:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b \quad (6)$$

Burada;

$f(x)$: Modelden üretilen tahmin değerlerini,

$K(x_i, x)$: Doğrusal olmayan ilişkileri çözümlemek amacıyla kullanılan Kernel fonksiyonu,

α_i ve α_i^* : Modelin sınırlarını çizen Lagrange çarpanları olarak isimlendirilen optimizasyon parametreleri,

b : Modelin sabit terimini göstermektedir.

SVR modeli, yapısal risk minimizasyonu ile aşırı öğrenmeyi engellemesiyle sınırlı veri setlerinde bile oldukça yüksek tahmin performansını yakalamaktadır.

3.3.1.6. K-En Yakın Komşu (KNN) Modeli

Doğrusal olmayan ilişkileri incelemek ve yeni gözlemler için tahminlerde bulunmak amacıyla kullanılan bir diğer parametrik olmayan yöntemdir. Model eğitimi sırasında herhangi bir parametre optimizasyonuna ihtiyaç duymayan, denetimli bir makine öğrenmesi yaklaşımıdır. Bu yöntemle, bir gözlem değerinin sınıfı veya regresyon değeri, eğitim veri setinde kendisine en yakın konumda bulunan k adet veri noktasının özelliklerine bakılarak hesaplanmaktadır. Temel amacı, belirtilen en yakın veri noktalarının sisteme yeni eklenen veri noktası ile benzer özellikler taşıma olasılığının yüksek olmasıdır. (Alşan, 2026; James vd., 2013).

KNN modelinin operasyonel süreci aşağıdaki adımlardan oluşmaktadır: Öncelikle, tahmin edilmek istenen yeni gözlem ile mevcut eğitim veri setindeki tüm gözlemler arasındaki geometrik mesafeler hesaplanır. Hesaplanan mesafe değerleri küçükten büyüğe sıralanarak hedef noktaya en yakın k sayıda komşu belirlenir. Son olarak seçilen komşuların bağımlı değişken değerleri üzerinden son tahmin çıktısı üretilir (Alşan, 2026).

Analiz aşamasında komşuların mesafelerini ölçmek için veri yapısına göre farklı mesafe metrikleri kullanılmaktadır. En sık tercih edilen metrikler Eşitlik (7), (8) ve (9)'da tanımlanmıştır (Alşan, 2026):

Öklid (Euclidean) Mesafesi:

$$d(x, y) = \sum_{i=1}^n (x_i - y_i)^2 \quad (7)$$

Manhattan Mesafesi:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i| \quad (8)$$

Minkowski Mesafesi:

$$d(x, y) = \left(\sum_{i=1}^n |x_i - y_i|^p \right)^{\frac{1}{p}} \quad (9)$$

Burada p parametresi Minkowski mesafesinin formunu belirlemektedir; $p = 1$ kısıtında formül Manhattan mesafesine, $p = 2$ kısıtında ise Öklid mesafesine dönüşmektedir. (Alşan, 2026).

3.3.1.7. Aşırı Gradyan Artırma (XGBoost) Modeli

Doğrusal olmayan, karmaşık ve etkileşimli etkileri yüksek doğrulukla tahmin etmek için literatürde sıkça kullanılan gelişmiş toplu öğrenme algoritmalarındandır. Tianqi Chen'in geliştirdiği ve gradyan artırma (gradient boosting) çerçevesine dayanan yöntem; ağaç tabanlı zayıf öğrencilerin ardışık bir düzen içinde eğitilmesi mantığıyla çalışmaktadır (Şenel Kahyaoğlu, 2026). İşlem suresince sisteme eklenen her yeni karar ağacı, kendisinden önce kurulan ağaçların ortaya çıkardığı tahmin hatalarını minimize etmeye ve bu hataları düzeltmeye odaklanmaktadır (Okutucu, 2026; Şenel Kahyaoğlu, 2026).

XGBoost modelinin amaç fonksiyonu, n gözlem ve K adet ağaç için Eşitlik (10)'deki gibi tanımlanmaktadır (Şenel Kahyaoğlu, 2026):

$$A = \sum_{i=1}^n a(y_i, \hat{y}_i) + \sum_{k=1}^K b(f_k) \quad (10)$$

$a(y_i, \hat{y}_i)$: Gerçek değer ile modelin tahmini arasındaki kayıp fonksiyonunu,

$b(f_k)$: Modelin aşırı öğrenmesini engellemek amacıyla kurgulanan düzenleme terimini ifade etmektedir.

BULGULAR VE TARTIŞMA

Bu bölüm altında hava kirleticilerinin halk sağlığı göstergeleri üzerindeki doğrusal ve doğrusal olmayan etkilerinin belirlenmesi için uygulanan istatistiksel ve makine öğrenmesi modellerinden elde edilen çıktılar bulunmaktadır. Araştırma kapsamında kurgulanan Doğrusal, Lasso, Ridge, Destek Vektör Regresyon modelleri, Random Forest, K-En Yakın Komşu, XGBoost algoritmalarının tahmin performansları ile değişken önem seviyeleri karşılaştırmalı şekilde analiz edilmiştir. Elde edilen bulgular sonucunda açıklanabilirliği (R^2) en yüksek olan iki modelde farklı senaryolar kurgulanarak halk sağlığı etki puanı üzerinde oluşturabileceği potansiyel sonuçlar simüle edilmiştir.

4.1. Klasik Çoklu Doğrusal Regresyon Modeli Bulguları

Hava kirletici, meteoroloji ve klinik vaka parametrelerinin Sağlık Etki Puanı üzerindeki etkilerini incelemek adına kurulan Klasik Çoklu Doğrusal Regresyon modelinin katsayı tahminleri, anlamlılık seviyeleri ve %95 güven aralığı değerleri Tablo 7’de gösterilmektedir.

Tablo 7. Çoklu Doğrusal Regresyon Modeli Katsayı Tahmin ve Güven Aralığı Sonuçları

Bağımsız Değişkenler	Katsayı (β)	Standart Hata	t Değeri	p Değeri	%95 Güven Aralığı
Sabit Terim	63.9122	0.9576	66.744	<0.001***	[62.0350, 65.7890]
AQI	0.0555	0.0010	56.931	<0.001***	[0.0536, 0.0574]
PM_{10}	0.0265	0.0016	16.122	<0.001***	[0.0233, 0.0298]
$PM_{2.5}$	0.0481	0.0024	19.827	<0.001***	[0.0433, 0.0528]
NO_2	0.0276	0.0024	11.325	<0.001***	[0.0228, 0.0323]
SO_2	0.0120	0.0049	2.440	0.0147*	[0.0024, 0.0216]
O_3	0.0249	0.0016	15.344	<0.001***	[0.0217, 0.0281]
Sıcaklık	-0.0079	0.0097	-0.819	0.4130	[-0.0269, 0.0110]
Nem	0.0026	0.0053	0.483	0.6292	[-0.0079, 0.0131]
Rüzgar Hızı	-0.0335	0.0243	-1.381	0.1674	[-0.0812, 0.0140]
Solunum Vakaları	0.0650	0.0460	1.413	0.1578	[-0.0252, 0.1554]

Kardiyovasküler Vakalar	-0.0024	0.0674	-0.037	0.9709	[-0.1346, 0.1297]
Hastane Yatışları	-0.0698	0.1052	-0.664	0.5070	[-0.2761, 0.1364]


Tablo 7’de sunulan veriler incelendiğinde, hava kirletici parametrelerinin halk sağlığı etki puanı üzerinde pozitif yönlü ve istatistiksel olarak anlamlı ($p < 0.05$) etkilere sahip olduğu gözlenmiştir. Bunun yanında, tablodaki sıcaklık, nem ve rüzgar hızı gibi meteorolojik parametrelerinin halk sağlığı etki puanı üzerindeki etkisi istatistiksel olarak anlamsız bulunmuştur ($p > 0.05$).

Tablo 8. KÇDR Modelinin Tahmin Performansı Sonuçları

Performans Metriği	Hesaplanan Değer
RMSE	9.4891
R^2	0.4999
MAE	7.1214


Modelin %20’lik test verisi üzerindeki tahmin başarısı Tablo 8’de özetlenmiştir. Bulunan sonuçlara göre, modelin test verisindeki ortalama hata miktarı $RMSE=9.4891$, varyansı açıklama oranı ise $R^2=0.4999$ olarak saptanmıştır.

Modeldeki bağımsız değişkenler arasında çoklu doğrusal bağlantı (multicollinearity) sorununun olup olmadığını kontrol etmek amacıyla hazırlanan VIF grafiği Şekil 2’de verilmiştir. Grafiğe bakıldığında, modele alınan tüm hava kirleticileri, meteorolojik faktörler ve klinik vaka değişkenlerinin VIF (varyans şişme faktörü) değerlerinin 1.00 referans çizgisine çok yakın, olduğu tespit edilmiştir. Literatürde çoklu doğrusal bağlantı sınırı için kritik eşik değer genel olarak 5 kabul edilmektedir (Hair vd., 2018; Montgomery vd., 2021). Şekil 2’ye göre kurulan Klasik Çoklu Doğrusal Regresyon modelinin katsayı tahminlerinin sapmasız, güvenilir ve regresyon varsayımlarına uyumlu olduğunu göstermektedir.




Şekil 2. VIF Değerleri

(2)




Şekil 3. Sağlık Etki Skorunun Gerçek ve Tahmin Değerlerinin Dağılım Grafiği (3)

Modelin test verileri üzerindeki tahmin performansına ait dağılım grafiği (Şekil 3) incelendiğinde klasik çoklu doğrusal regresyon modeli, Sağlık Etki Skorunu 40 ile 90 aralığında başarıyla modellemiştir. Ancak, Sağlık Etki Skorunun üst sınırı olan 100 noktasında dikey yığılma görülmektedir. Doğrusal yapı, uç değerlerdeki ani varyasyonları ve dağılımdaki asimetriyi yansıtmada yetersiz kalmıştır.



Şekil 4. KÇDR Modelinin Hata ve Tahmin Değerleri Dağılım Grafiği (4)

Modelin En Küçük Kareler varsayımlarını sınavan artık analizi grafiği (Şekil 4) incelendiğinde, modelin yetersiz kaldığı daha anlaşılır şekilde görülmektedir. Klasik Çoklu Doğrusal Regresyon varsayımlarına göre hataların ideal modellerde sıfır çizgisi etrafında rastgele dağılmış olması gerekmektedir (Gujarati & Porter, 2012). Fakat grafikte görüldüğü üzere bir “V” dağılımı oluşmuştur. Hataların bu sistematik dağılımı modelde değişen varyans ve doğrusalsızlık sorunlarının olduğunu göstermektedir.



Şekil 5. KÇDR Modelinin Hata Frekans Dağılım Histogramı (5)

Hataların istatistiksel dağılımını incelemek için oluşturulan artık histogramı (Şekil 5) hataların sıfır etrafında simetrik normal dağılım göstermesi beklenirken (Akdeniz, 2012), hata dağılımının simetrik olmayan sola çarpık bir dağılım sergilediğini göstermektedir. Bu bulgu, modelin normal dağılım varsayımını ihlal ettiğini göstermektedir (Felek, 2025).

4.2. Lasso Regresyon Modeli Bulguları

Lasso Regresyon modeli L_1 terimiyle anlamsız ya da etkisi göz ardı edilebilecek değişkenleri katsayılarını sıfıra eşitleyerek modelden uzaklaştırmaktadır. Bu yöntemle Klasik Çoklu Doğrusal Regresyon modeline karşı avantajlıdır (Tibshirani, 1996). Modelde çapraz doğrulama ile belirlenen en uygun ceza parametresi (λ) altında katsayı optimizasyonu yapılmıştır.

Tablo 9. Lasso Modeli Önem Sırasına Göre Optimize Edilmiş Katsayılar


Değişkenler	Katsayılar
Sabit Terim	65.0868
Hastane Yatışları	-0.1120
AQI	0.0558
$PM_{2.5}$	0.0492
Kardiyovasküler Vakalar	-0.0437
Rüzgar Hızı	-0.0337
PM_{10}	0.0262
NO_2	0.0261
O_3	0.0249
SO_2	0.0087
Sıcaklık	-0.0082
Nem	0.0003
Solunum Vakaları	0.0000

Elde edilen katsayılar incelendiğinde Solunum Vakalarının katsayısı sıfıra indirgenerek modelden uzaklaştırıldığı görülmektedir. Önem sırasında mutlak değerce en yüksek katsayıya sahip değişkenin Hastane Yatışları olduğu tespit edilmiştir.

Tablo 10. Lasso Modelinin Tahmin Performansı Sonuçları


Performans Metriği	Hesaplanan Değer
R^2	0.4805
RMSE	9.3652
MAE	7.3988

Lasso Modelin %20'lik test verisi üzerindeki tahmin basarisi Tablo 10'da özetlenmiştir. Bulunan sonuçlara göre, modelin test verisindeki ortalama hata miktarı $RMSE = 9.3652$, varyansı açıklama oranı ise $R^2 = 0.4805$ ve ortalama mutlak hata $MAE = 7.3988$ olarak saptanmıştır.




Şekil 6. Lasso Modeli Çapraz Doğrulama λ ve Hata Dağılım Grafiği (6)

Modelde aşırı öğrenmeyi engelleyen λ parametresinin k -katlı çapraz doğrulama ile belirlenme aşamasını ortaya koymaktadır. Grafikte sol kısımdaki kesikli çizgi, tahminin hatasını (MSE) en alt seviyeye düşüren λ_{min} değerini; sağdaki kesikli çizgi ise standart hata seviyesi içinde kalarak en yalın modeli sunan λ_{1se} seviyesini göstermektedir (Friedman vd., 2010).



Şekil 7. Lasso Model Katsayı İnceleme Grafiği (7)


Grafik soldan sağ yönünde incelendiğinde λ parametresinin küçülmesine bağlı modele eklenen değişken sayısının 1'den 12'ye çıktığı saptanmıştır. Katsayıların belirli aşamalarda sıfır çizgisinde olması, modelin istatistiksel anlamsız değişkenleri modelden atma şeklini anlatmaktadır.



Şekil 8. Lasso Modelde Parametre Katsayılarının Etki Gücü (8)


Parametre katsayılarının etki gücü grafiği (Şekil 8) incelendiğinde, bağımsız değişkenlerin bağımlı değişken üzerindeki önemi ve etki yönü görülmektedir.

Grafiğe göre; Sağlık Etki Puanını negatif yönlü en fazla etkileyen değişkenin Hastane yatışları, pozitif yönlü en fazla etkileyen değişkenin ise AQI olduğu tespit edilmiştir.



Şekil 9. Sağlık Etki Skorunun Gerçek ve Tahmin Değerlerinin Dağılım Grafiği (9)

Modelin test verileri üzerindeki tahmin performansına ait dağılım grafiği (Şekil 9) incelendiğinde Lasso modeli, Sağlık Etki Skorunu 40 ile 90 aralığında başarıyla modellemiştir. Ancak, Sağlık Etki Skorunun üst sınırı olan 100 noktasında dikey yığılma görülmektedir. Model, uç değerlerdeki kümelenen varyasyonu esnetmede yetersiz kalmıştır.



Şekil 10. Lasso Modelinin Hata Frekans Dağılım Histogramı (10)

Şekil 10’da hata dağılımının simetrik olmayan sola çarpık bir dağılım gösterdiği saptanmıştır. Bu bulgu, modelin normal dağılım varsayımından sapma gösterdiğini

ve hipotez sınamalarının güvenilirliğini düşürdüğünü ortaya koymaktadır (Gujarati & Porter, 2012).

4.3. Ridge Regresyon Modeli Bulguları

Lasso modelinden farklı olarak, Ridge model hiçbir değişkenin katsayısını sıfırlamamıştır (Hastie vd., 2009). L_2 ceza mekanizmasının değişkenler üzerindeki etkisi Tablo 11'deki gibidir.

Tablo 11. Ridge Modeli Önem Sırasına Göre Optimize Edilmiş Katsayılar


Değişkenler	Katsayılar
Sabit Terim	66.5276
Hastane Yatışları	-0.1550
Kardiyovasküler Vakalar	-0.06512
AQI	0.0530
$PM_{2.5}$	0.0473
Rüzgar Hızı	-0.0430
NO_2	0.0255
PM_{10}	0.0254
O_3	0.0241
Sıcaklık	-0.0111
SO_2	0.0098
Solunum Vakaları	-0.0042
Nem	0.0021

Tablo 11'e göre Ridge modelin, Lasso model aksine Solunum Vakaları değişkeninin katsayısını sıfırlamadığı tespit edilmiştir.

Tablo 12. Ridge Modelinin Tahmin Performansı Sonuçları


Performans Metriği	Hesaplanan Değer
R^2	0.4800
RMSE	9.3641
MAE	7.3026

Ridge Modelin yine aynı şekilde %20'lik test verisi için tahmin başarısı Tablo 12'da özetlenmiştir. Yapılan analiz sonuçlarına göre, modelin ortalama hata miktarı RMSE= 9.3641, varyansı açıklama oranı ise $R^2=0.4800$ ve ortalama mutlak hata MAE = 7.3026 olarak bulunmuştur.



Şekil 11. Ridge Modeli Çapraz Doğrulama Log (λ) ve Hata Dağılım Grafiği (11)


Ridge modelinin çapraz doğrulama sonuçları Şekil 11’de verilmiştir. Şekle göre λ ceza parametre değeri artsa bile modeldeki değişken sayısı 12 değişmemiştir. Grafikte verilen sol kısımdaki kesikli çizgi en az hatayı sağlayan λ_{min} değerini sağ kısımdaki kesikli çizgi ise standart hata seviyeli λ_{lse} sınırını göstermektedir (Friedman vd., 2010).



Şekil 12. Ridge Model λ ’ ya göre Katsayı Değişim Grafiği (12)


λ ’ ya göre katsayı değişim grafiği (Şekil 12) değerlendirildiğinde ceza değeri arttıkça değişkenlerin katsayı değerlerinin sıfıra yaklaştığı ancak hiçbir zaman

sıfırlanmadığı tespit edilmiştir. Bu sonuç, Ridge regresyonunun değişken secimi yapmayıp bütün parametreleri model içinde sakladığı çıkarımını yaptırmaktadır.




Şekil 13. Ridge Modelde λ ' ya göre Katsayı L_2 Normu Değişim Grafiği (13)

Şekil 13'te verilen grafikteki düşey eksen L_2 normunu (katsayıların kareköklerinin toplamının karekökü), yatay eksen ise $\text{Log}(\lambda)$ 'yı ifade etmektedir (Hastie vd., 2009). Grafiğe bakıldığında $\text{Log}(\lambda) < 1$ seviyesinde katsayıların toplam büyüklüğünün en yüksek olduğu seviyede (yaklaşık 0.19) sabitlendiği fark edilmiştir. Ceza miktarı $2 \leq \text{Log}(\lambda) \leq 6$ seviyesindeyken katsayılarda ciddi bir düşüş söz konusudur. Ve ceza miktarı maksimum seviyeye ($\text{Log}(\lambda) \approx 9$ seviyesine) çıktığında L_2 normu sıfırlanmamıştır.



Şekil 14. Ridge Modelinin Hata Frekans Dağılım Histogramı (14)

Şekil 14'te hata dağılımının simetrik olmayan sola çarpık bir dağılım gösterdiği saptanmıştır. Bu bulgu, L_2 normuyla katsayıların varyansını dengelese de doğrusal modellerin normal dağılım varsayımını karşılayamadığını anlatmaktadır (Gujarati & Porter, 2012).




Şekil 15. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği (15)

Ridge regresyon modelinin test verisindeki değerler üzerindeki tahmin performansına ait dağılım grafiğine (Şekil 15) bakıldığında model, Sağlık Etki Skorunu 40 ile 85 aralığında doğrusal eğimle tutarlı şekilde modellemiştir. Ancak, Sağlık Etki Skorunun maksimum limiti olan 100 noktasında düşey bir yığılma söz konusudur. Bunun yanı sıra grafikte görüldüğü üzere hatasız tahmin çizgisi ile gözlem değeri arasında bir sapma tespit edilmiştir. Bu sebeplerle birlikte, model veri setini açıklamakta yetersiz kalmıştır.

4.4. Rastgele Orman (Random Forest) Modeli Bulguları

Hava kirleticilerle halk sağlığı arasındaki doğrusal olmayan etkileşimleri incelemek için Rastgele Orman modeli kurgulanmıştır. Modelin eğitim aşamasında, 500 karar ağacı oluşturulmuş ve karar ağaçlarının dallanma noktalarına rastgele 4 bağımsız değişken atanmıştır. Modelden seçilen karar ağaçlarından birinin dallanma yapısı Şekil 16'da verilmiştir.



Şekil 16. Rastgele Orman Modeli Örnek Karar Ağacı Dallanma Yapısı (16)


Şekil 16’da verilen örnek karar ağacına bakıldığında, modelin Hava Kalitesi İndeksinin (AQI) 98’den küçük olması kriterine göre yapıldığı görülmektedir. Hava kalitesinin kötü olduğu sağ tarafta AQI değerinin 147 veya daha üstüne çıkmasıyla model veri setinin %70’ini kapsayan en yüksek sağlık etki skoruna erişmektedir. Daha temiz havayı yansıtan sol tarafta ise $PM_{2.5}$ ve PM_{10} seviyelerine göre sağlık etki skoru aşamalı şekilde azalmaktadır.

Tablo 13. Rastgele Orman Modelinin Tahmin Performansı Sonuçları

Performans Metriği	Hesaplanan Değer
R^2	0.9467
RMSE	3.5003
MAE	1.8911


Modelin tahmin performansı metriklerini veren Tablo 13 incelendiğinde Rastgele Orman modelinin test verisi için tahmin tutarlılığının oldukça yüksek olduğu belirlenmiştir. Modelin ortalama hata miktarı $RMSE = 3.5003$, varyansı açıklama oranı $R^2 = 0.9467$ ve ortalama mutlak hata $MAE = 1.8911$ olarak hesaplanmıştır.

Rastgele Orman modelinde ağaç sayısı arttıkça hata oranının ilk önce süratle azaldığı daha sonra sabitlendiği ve yapısı sayesinde aşırı öğrenmeye karşı dayanıklı olması varsayımıyla ağaç sayısına göre hata oranı grafiği (Şekil 17) çizdirilmiştir (Breiman, 2001).




Şekil 17. Ağaç Sayısına Göre Hata Oranı Grafiği (17)

Şekil 17'ye göre modeldeki hata oranının ilk önce hızla azaldığı ve ortalama 100 ağaçtan sonra en alt hata seviyesinde sabitlendiği tespit edilmiştir. Bu grafik, model için karar verilen 500 ağaç yapılanmasının modeli kararlı ve aşırı öğrenmeyi engelleyen hale getirmekte yeterli olduğu kanıtlanmaktadır.




Şekil 18. Değişkenlerin Önem Seviyeleri Grafiği (18)

Şekil 18 de gösterilen hata oranındaki yüzdelik artışa bakıldığında; Rastgele Orman modelinde sağlık etki skorunu en fazla açıklayabilen değişkenin büyük bir farkla hava kalitesi indeksi (AQI) olduğu açıktır, AQI değişkeninden sonra hava kirletici değişkenlerinin açıklama oranının yüksek olduğu saptanmıştır. Bunun yanında, meteorolojik faktörler ve sağlık göstergeleri incelediğinde bu değişkenlerin modele katkısının oldukça düşük olduğu görülmektedir.



Şekil 19. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği (19)

Rastgele Orman modelinin test verisindeki değerler üzerindeki tahmin performansına ait dağılım grafiğinde (Şekil 19) model, Sağlık Etki Skorunu 40 ile 80 aralığında gerçek değerlerin biraz üstünde tahminleme yönelimindedir. Ancak, Sağlık Etki Skorunun tepe noktası olan 100 noktasında dikine bir yığılmanın mevcutluğu söz konusudur. Grafikte, ideal tahmin doğrusundan aşırı sapan değerlerin var olmaması modelin kararlı ve güvenilir olduğunu belirtmektedir.



Şekil 20. Rastgele Orman Modelinin Hata Frekans Dağılım Histogramı (20)

Şekil 20’de hata dağılımının sıfır etrafında sık şekilde gruplandığı gözlenmektedir. Bu bulgu, modelin tahmin basarisinin üst seviyede olduğunu onaylamaktadır. Bunun yanında histogram incelendiğinde dağılımın -genel olarak simetrik olsa da- düşük bir asimetriye de sahip olduğu söylenebilmektedir. (James vd., 2013).

4.5. K-En Yakın Komşu (KNN) Modeli Bulguları


Hava kirleticilerin halk sağlığındaki etkilerini çıkarsamak amacıyla K-En Yakın Komşu modeli kurulmuştur. Uzaklıklar hesaplanırken birim farklılıkların modeli

hatalı yönlendirmemesi için veri setindeki bütün değişkenler ilk olarak standardize edilmiştir. Daha sonrasında model başarısını artırmak için 5 katlı çapraz doğrulama sisteme dahil edilmiştir. Son aşamada, en doğru çıkarımı sağlayan komşu sayısı 10 farklı değer arasından tercih edilmiştir.

Tablo 14. K- En Yakın Komşu Modelinin Tahmin Performansı Sonuçları

Performans Metriği	Hesaplanan Değer
R^2	0.7602
RMSE	7.8163
MAE	4.0247

Modelin tahmin performansı metriklerini veren (Tablo 14) incelendiğinde yapılan analiz sonucuna göre 5 katlı çapraz doğrulamayla en az hata payına sahip optimal komşu sayısı $k = 11$ olarak bulunmuştur. Bu düzenlemeyle, modelin test seti üzerindeki ortalama hata miktarının $RMSE = 7.8163$, varyansı açıklama oranının $R^2 = 0.7602$ ve ortalama mutlak hatanın $MAE = 4.0247$ olduğu hesaplanmıştır.




Şekil 21. K- Komşu Sayısına Göre RMSE Değişim Grafiği (21)

Şekil 21'deki grafiğe bakıldığında, $k = 5$ noktası ve sonrasında komşu sayısının fazlalaşmasıyla hata oranının aşamalı şekilde azalıp performansın daha iyi sonuç verdiği tespit edilmiştir. Verilen analiz çıktısında en düşük RMSE değerinin $k = 11$ noktasında yakalandığı bulunmuştur. Komşu sayısının 11'i geçmesi modeli aşırı genellemeye düşürmüştür ve RMSE değerlerini yükseltmiştir.




Şekil 22. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği (22)

K-En Yakın Komşu modelinin test verisindeki değerler üzerindeki tahmin performansına ait dağılım grafiğinde (Şekil 22) sol kısma odaklanıldığında, modelin Sağlık Etki Skorunu düşük ve orta risk aralıklarında gerçek değerlerin biraz üstünde tahminleme yöneliminde olduğu aşikardır. Ancak, Sağlık Etki Skorunun tepe noktası olan 100 noktasında dikine bir yığılmanın mevcutluğu söz konusudur. Model, uzaklık odaklı yapısı sebebiyle uç noktadaki gözlemleri de kabul edilebilir bir varyans aralığında tahminleyebilmiştir.



Şekil 23. K-En Yakın Komşu Modelinin Hata Frekans Dağılım Histogramı (23)

Şekil 23'te hata dağılımının sıfır etrafında yoğunlaştığı gözlenmektedir. Alpar'ın (2020) da savunduğu gibi bu bulgu, modelin tahmin doğruluğunun yüksek olduğunu onaylamaktadır. Bunun yanında histogram incelendiğinde modelin sola çarpık dağılıma sahip olduğu söylenebilmektedir. Ancak sıfır etrafındaki yoğun toplanma modelin kabul edilebilir sapmalarla öngörü işlemi yaptığını göstermektedir.



Şekil 24. K-En Yakın Komşu Kategorik Performans Matrisi (24)

Şekil 24’te verilen performans matrisine bakıldığında, örneklerin büyük kısmı “Çok Yüksek” kategorisindedir. Model bu kategorideki örneklerin %99.9’unu doğru tahmin etmiştir.

Ancak bu performans matrisiyle analiz tamamlanmayarak modelin daha fazla kategorilerdeki başarısı araştırılmıştır.

Tablo 15. KNN Kategori Sayısına Göre Hata Oranı Tablosu

Kategori Sayısı	Hata Oranı
4	%9.5406
10	%20.5830

Tablo 15’e göre kategori sayısı 4 olduğundaki hata oranının (%9.5406) düşük seviyede olduğu gözlenmektedir. Kategori sayısı 10’a yükseltilerek kategoriler daraltıldığında hata oranının (%20.5830) artması, modelin makullüğünü ispatlamaktadır (James vd., 2013).


4.6. Destek Vektör Regresyon (SVR) Modeli Bulguları

Hava kirleticilerle halk sağlığı arasındaki doğrusal olmayan etkileşimleri araştırmak için Destek Vektörü Regresyon modeli kurgulanmıştır. Modelin eğitim aşamasında, parametrelerin kararlılığını açıklayan toplam destek vektör sayısının 2669 olduğu bulunmuştur.

Tablo 16. Destek Vektör Regresyon Modelinin Tahmin Performansı Sonuçları


Performans Metriği	Hesaplanan Değer
R^2	0.9538
RMSE	2.9165
MAE	2.1776

Modelin tahmin performansı metriklerini veren Tablo 16’da görüldüğü üzere Destek Vektör Regresyon modelinin test setindeki tahmin tutarlılığının son derece iyi olduğu saptanmıştır. Modelin ortalama hata miktarı $RMSE=2.9165$, varyansı açıklama oranı $R^2=0.9538$ ve ortalama mutlak hata $MAE=2.1776$ olarak hesaplanmıştır.



Şekil 25. Bağımlı Değişkenin Gerçek ve Tahmin Değerlerinin Dağılım Grafiği (25)

Destek Vektör Regresyon modelinin test verisindeki değerler üzerindeki tahmin performansına ait dağılım grafiğinde (Şekil 25) gözlem değerlerinin ideal uyum çizgisi çevresinde gruplandığı tespit edilmiştir. Uyum çizgisine bu kadar yakın dağılıma modelin yüksek varyanslı değerlerde de başarılı olacağını göstermektedir (Smola & Schölkopf, 2004). Ancak, Sağlık Etki Skorunun tepe noktası olan 100 noktasında dikine yoğun bir yığılma söz konusudur. Model, uç noktadaki gözlemleri de kabul edilebilir sapma sınırlarında tahminleyebilmiştir.



Şekil 26. Destek Vektör Modelinin Hata Frekans Dağılım Histogram (26)

Şekil 26’de hata dağılımının sıfır etrafında yoğunlaştığı gözlenmektedir. Bu bulgu, modelin tahmin doğruluğunun yüksek olduğunu onaylamaktadır (Alpar, 2020). Bunun yanında histogram incelendiğinde modelin sağ ve sol yanlarındaki hata

dağılımlarının birbirine benzer ve dengeli olduğu söylenebilmektedir. Histogram, modelin halk sağlığı etki skoru üzerinde iyi performanslı öngörü işlemi yaptığını göstermektedir.


4.7. Aşırı Gradyan Artırma (XGBoost) Modeli Bulguları

XGBoost modelinin eğitimi aşamasında aşırı öğrenmeyi engellemek için öğrenme hızı 0.05 ve ağaç derinliği 6 olarak belirlenmiştir. Ve toplam 1000 adımlık optimizasyon süreci izlenmiştir.

Tablo 17. Xgboost Modelinin Tahmin Performansı Sonuçları


Performans Metriği	Hesaplanan Değer
R^2	0.9710
RMSE	2.4811
MAE	1.4230

Modelin tahmin performansı sonuçlarında (Tablo 17) görüldüğü üzere XGBoost modelinin test verisinde tahmin başarısının son derece iyi olduğu saptanmıştır. Modelin ortalama hata miktarı $RMSE= 2.4811$, varyansı açıklama oranı $R^2=0.9710$ ve ortalama mutlak hata $MAE = 1.4230$ olarak hesaplanmıştır.




Şekil 27. Değişkenlerin Önem Sıralaması (27)

Şekil 27’de gösterilen değişken önem sıralamasına bakıldığında; XGBoost modelinde sağlık etki skorunu en fazla açıklayabilen değişkenin büyük bir farkla (%60’ın üstünde) hava kalitesi indeksi (AQI) olduğu belirgindir, AQI değişkeninden sonra hava kirletici değişkenlerinin açıklama oranının yüksek olduğu saptanmıştır. Bunun yanında, meteorolojik faktörler ve sağlık göstergeleri incelediğinde bu değişkenlerin modele katkısının oldukça düşük olduğu görülmektedir.




Şekil 28. XGBoost Modeli SHAP Değerleri ve Etki Yönü (28)

XGBoost modelinin “kara kutu” yapısının açıklanması için SHAP analizi yapılmış ve sonuçlar şekil 28’de verilmiştir. Grafikteki düşey merkez çizgisi değişkenlerin etkisiz olduğunu, değerlerin sağa veya sola kayması ise etki yönünü göstermektedir (Lundberg & Lee, 2017). Modeldeki açıklayıcı en baskın parametrenin hava kalitesi indeksi olduğu aşıkardır. AQI değerleri arttıkça SHAP değerlerinin pozitif kısımda azaldıkça negatif kısımda kümelendiği görülmektedir. Benzer şekilde $PM_{2.5}$, PM_{10} ve O_3 parametrelerinde de bu durum gözlenmektedir. Meteorolojik faktörler ve sağlık göstergeleri ise bağımlı değişken üzerinde anlamlı bir etki göstermemektedir.




Şekil 29. XGBoost Modeli Yakınsama Analizi (29)

XGBoost modelinin eğitiminde ağaç sayısına göre RMSE değerleri (Şekil 29) verilmiştir. Şekle bakıldığında başta yüksek olan hata oranının ilk 75 ağaçla birlikte sertçe azaldığı gözlenmektedir. 100. ağaçtan sonra hem eğitim hem de test çizgilerinin sıfıra yaklaşarak sabitlendiği tespit edilmiştir. Bu sonuç, modelin aşırı öğrenmeden uzak optimal tahminler yaptığını göstermektedir.



Şekil 30. Gerçek ve Tahmin Değerlerinin Olasılık Yoğunluk Grafiği (30)

XGBoost modelinin olasılık yoğunluk grafiğinde (Şekil 30) görüldüğü üzere, gerçek değerler ile tahmin değerleri karşılaştırılmıştır. Modelin 20 ile 90 etki skorları arasında birebir örtüşen tahminler yaptığı görülmektedir. Sağlık etki puanının 100 olduğu değerlerde düşey kümelenme model tarafından belirlenebilmiştir. Gerçek değerleri gösteren eğrinin keskin tepe noktasının aksine daha geniş eğri çizmesi modelin sınır değerleri yumuşatma yöneliminden dolayıdır (Montgomery vd., 2021).



Şekil 31. Hastalık Türlerine Göre Değişkenlerin Önem Seviyeleri (31)

Şekil 31'e göre Solunum yolu vakalarına en çok sebebiyet veren değişkenlerin sırasıyla PM_{10} , Rüzgar Hızı ve Nem olduğu saptanmıştır. Literatürde rüzgar hızının hava kirleticileri taşıyarak hastalık yaydığı nemin ise kirleticileri hapsettiği için hastalık yaydığı belirtilmiştir (Dominici vd., 2006; Pope vd., 2002). Kardiyovasküler vakalara ise en çok neden olan değişkenlerin AQI, PM_{10} ve $PM_{2.5}$ olduğu görülmektedir.

4.8. Kurulan Modellerin Karşılaştırılması


Bu kısma kurulan bütün modellerin performans metrikleri karşılaştırılarak saptanan bulgular eklenmiştir.

Tablo 18. Kurulan Modellerin Tahmin Performansı Sonuçları

Model	R^2	RMSE	MAE
KÇDR	0.4999	9.4891	7.1214
Lasso	0.4805	9.3652	7.3988
Ridge	0.4800	9.3641	7.3026
Rastgele Orman	0.9467	3.5003	1.8911
K-NN	0.7602	7.8163	4.0247
SVR	0.9538	2.9165	2.1776
XGBoost	0.9710	2.4811	1.4230

Tüm modellerin performans metrikleri (Tablo 18) incelendiğinde veri setinin varyansını en iyi açıklayabilen modelin XGBoost olduğu ve hemen ardından onu SVR modelinin takip ettiği belirlenmiştir. En iyi ortalama hataya sahip modelin ise yine XGBoost ve sonrasında SVR olduğu görülmektedir. Mutlak ortalama hatası en az olan modellerin yine XGBoost olduğu ve ikinci mutlak ortalama hatası en az olan modelin ise Rastgele Orman modeli olduğu saptanmıştır.

Modellerin performans metriklerinin aralarındaki mesafenin daha iyi görülmesi için (Şekil 32)'e bakılması yeterlidir.



Şekil 32. Modellerin Performans Metriklerinin Görselleştirilmesi (32)

Veri setini açıklamada en başarılı ve en düşük hataya sahip modellerin sırasıyla XGBoost, SVR ve Random Forest olduğu, açıklanabilirliği ve hatası ortalama düzeyde olan modelin K-NN modeli olduğu görülmektedir. KÇDR, Lasso ve Ridge modelleri ise veri setini açıklamada yetersiz kalmasıyla birlikte tahmin hatalarının diğerlerine kıyasla yüksek olduğu belirlenmiştir.

4.9. Log Dönüşümü ve Standardizasyon İşlemi Bulguları

Açıklanabilirliği (R^2) en iyi olan iki modelde log dönüşümü ve standardizasyon işlemleri denenerek modelin açıklanabilirliği optimize edilmeye çalışılmıştır.

Tablo 19. Standardizasyon Ve Log Dönüşümü R^2 Değerleri

Model	Başlangıç R^2	Standardizasyon	Log Dönüşümü
SVR	0.9538	0.9538	0.9315
XGBoost	0.9710	0.9709	0.9702

Tablo 19'daki sonuçlar karşılaştırıldığında başlangıçtaki modelin R^2 değerine çok yakın sonuçlar çıktığından dolayı modellere logaritmik dönüşüm veya standardizasyon işlemleri yapılmadan duyarlılık analizinin yapılmasına karar verilmiştir.

4.10. Duyarlılık Analizi Bulguları

Bu kısımda açıklanabilirliği (R^2) en iyi olan iki modelde farklı senaryo denemeleriyle bağımsız değişkenlerin Solunum Yolu Vakalarını, Kardiyovasküler Vakaları ve Sağlık Etki Puanını hangi yönde ve ne kadar etkilediği tahmin edilmiştir. Uygulanan senaryolar hava kirleticilerinin %20 azalması, %10 artması ve meteorolojik faktörlerin değişimi (Sıcaklığın %10 artması, Nemin %10 azalması, Rüzgar Hızının %20 azalması) olarak belirlenmiştir.

Tablo 20. Hava Kirleticilerinin %20 Azalması Senaryosu

Hastalık Türü	Model	Değişim
Kardiyovasküler Vaka	XGBoost	-1.8184
Kardiyovasküler Vaka	SVR	-1.0091
Solunum Yolu Vaka	SVR	0.8559
Solunum Yolu Vaka	XGBoost	-0.0069

Hava kirleticilerinin %20 azaltıldığı senaryonun analizi sonuçları Tablo 20'de gösterilmektedir. XGBoost modeli ile SVR modeli kardiyovasküler vakalarda birbirlerine yakın sonuçlar üretmiştir. Ancak solunum yolu vakalarında XGBoost düşüş tahmin ederken SVR modeli artış tespit etmiştir. Solunum yolu vakalarındaki kararsızlık bu hastalık türünün anlık hava temizliğine göre hızlı değişmemesiyle bağdaştırılmıştır (Samet vd., 2000).

Tablo 21. Hava Kirleticilerinin %10 Artması Senaryosu

Hastalık Türü	Model	Değişim
Kardiyovasküler Vaka	XGBoost	0.3752
Kardiyovasküler Vaka	SVR	1.1067

Solunum Yolu Vaka	SVR	-0.1729
Solunum Yolu Vaka	XGBoost	2.1966

Hava kirleticilerinin %10 azaltıldığı senaryo analizinin sonuçları Tablo 21’de verilmiştir. XGBoost modeli solunum yolu vakalarının %2.19 oranında artacağını söylerken SVR modeli buna katılmayarak %0.17 azalış olacağını söylemiştir. Bunun temel sebebi iki modelin matematiksel yapılarının birbirlerinden farklı olmasıdır (Chen & Guestrin, 2016). Diğer yandan SVR modelinin %1.1, XGBoost modelinin %0.37’lik artışı hava kalitesinin kötüleşmesinin Kardiyovasküler vakalardaki ani etkisini açıklamaktadır.

Tablo 22. Meteorolojik Faktörlerin Değişimi Senaryosu

Hastalık Türü	Model	Değişim
Kardiyovasküler Vaka	XGBoost	-0.3147
Kardiyovasküler Vaka	SVR	-0.4720
Solunum Yolu Vaka	SVR	0.1005
Solunum Yolu Vaka	XGBoost	0.0599

Meteorolojik faktörlerin değişimi senaryosunun sonuçları Tablo 22’de gösterilmiştir. Sıcaklığın %10 artması, nemin %10 azalması ve rüzgar hızının %20 azalmasıyla her iki modele göre kardiyovasküler vakalarda azalma yaşanacağı öngörülmektedir. Solunum yolu vakalarında ise modeller bu değişimin ters yönde yani hastalık riskinin artacağını söylemektedir.

Tablo 23. Senaryoların Sağlık Etki Puanı Değişimi Tahmini

Model	Senaryo	Değişim
XGBoost	Hava Kirleticileri + %20	-5.4668
XGBoost	Hava Kirleticileri – %10	1.6068
XGBoost	Meteorolojik Değişim	-0.1122
SVR	Hava Kirleticileri + %20	-5.9835
SVR	Hava Kirleticileri – %10	1.7457
SVR	Meteorolojik Değişim	0.0066

Tablo 23 incelendiğinde hava kirleticilerinin %20 azaltıldığı senaryoda XGBoost modeli sağlık etki puanında %5.46 azalış tahmin ederken SVR modeli %5.98’lik bir azalış tahmin etmiştir. Bir diğeri olan hava kirleticilerinin %10 azaltıldığı senaryoda ise XGBoost modeli sağlık etki puanında %1.6 azalış öngörürken SVR modeli %1.74’lük bir artış öngörmüştür. Son senaryo olan meteorolojik faktörlerin değişimi senaryosunda ise XGBoost modeli sağlık etki puanında %0.11’lik bir azalış tespit ederken SVR modeli %0.006’lik bir artış tespit etmiştir. Bu sonuçlar, hava kirleticilerinin halk sağlığı üzerindeki riski belirlemede meteorolojik faktörlere göre daha etkin rol aldığını kanıtlamaktadır.

5 SONUÇ

Bu çalışmada; hava kirleticilerinin ve meteorolojik faktörlerin sağlık etki puanı üzerindeki doğrusal ve doğrusal olmayan etkileri, istatistiksel metotlarla ve makine öğrenmesi algoritmalarıyla kıyaslanarak ele alınmıştır. Sınanan KÇDR, Lasso, Ridge, KNN, Rastgele Orman, SVR ve XGBoost modellerinin tahmin yetenekleri değişkenlerin önem düzeylerine ve sınır değerleri modelleme başarısına göre test edilmiştir. Bulunan sonuçlar, hava kirleticilerinin halk sağlığı üzerindeki varsayımlarını sınayarak aralarındaki nedensel ilişkiyi açıklamaktadır.

Kurgulanan modellerin performans metrikleri kıyaslandığında; doğrusal modeller olan KÇDR, Lasso ve Ridge modellerinin veri setinin varyansını açıklamada yetersiz kaldığı ve yüksek tahmin hataları yaptığı görülmektedir. En küçük kareler metodunun kabullerini sınamak amacıyla çizdirilen hata analizi grafiklerinde sıfır ekseninde hataların rastgele dağılması beklenirken “V” şeklinde dağılması modelin doğrusalsızlık ve varyansın değişmesi problemlerine sahip olduğunu doğrulamaktadır. Bunun yanında histogram grafiklerinin sola çarpık yapıları çıkarımsal istatistik varsayımlarından biri olan hatanın normal dağılımı varsayımını karşılayamadığını açıkça ortaya koymuştur (Gujarati & Porter, 2012). KÇDR modelinde VIF analiziyle değişkenler arasında çoklu doğrusal bağlantı olmadığı kanıtlanmıştır. Ancak doğrusal modeller, bütün sonuçlar bir arada incelendiğinde üst sınır değerlerini tahmin etmekte yeterli olamamıştır.

Aynı zamanda, veri setindeki doğrusal olmayan ilişkilerin makine öğrenmesi algoritmalarıyla, başarıyla tahmin edildiği saptanmıştır. Bütün makine öğrenmesi algoritmaları karşılaştırıldığında veri setinin varyansını açıklama kapasitesi en yüksek olan algoritmanın XGBoost olduğu görülmüştür. XGBoost modelini çok yakın performans sonuçlarıyla SVR ve Rastgele Orman modelleri takip etmiştir. KNN algoritması ise komşu sayılarının çapraz doğrulamayla iyileştirilmesine ve kategorilere ayrılmış matrislerinde "Çok Yüksek" kategorisini %99.9 oranında doğru tahmin etmesine rağmen, uzaklık tabanlı mimarisinden kaynaklı veri seti varyansını açıklayabilmede ortalama bir performans seviyesinde sonuç vermiştir.

XGBoost modeline eklenen SHAP analizi çıktısı, Sağlık Etki Puanı üzerinde etkisi en yüksek olan değişkenin açık ara farkla Hava Kalitesi İndeksi (AQI) olduğunu göstermektedir. AQI değişkeninden sonra bağımlı değişkeni en fazla etkileyenlerin PM_{10} , $PM_{2.5}$ ve SO_2 kirleticileri olduğu tespit edilmiştir. SHAP bağımlılık grafikleri, hava kirleticilerinin belirli bir sınır değerini aştıktan sonra sağlık etki puanı üzerindeki etkisinin pozitif yönlü olarak etkilendiği bulunmuştur (Lundberg & Lee, 2017). Meteorolojik faktörlerin halk sağlığı üzerindeki etkisinin düşük olduğu gözlenirse de solunum ve kardiyovasküler vakalar incelendiğinde rüzgâr hızı ve nemin, hava kirleticilerini hapsedme ve taşıma durumları nedeniyle solunum yolu vakalarında; partikül maddelerin ise doğrudan

dolařım sistemine karıřabilmeleri sebebiyle kardiyovasküler vakalarda tetikleyici rolleri olduđu saptanmıřtır (Dominici vd., 2006; Pope vd., 2002).

Arařtırmada veri seti varyansını aıklama yeteneđi en yksek olan iki modelde (XGBoost ve SVR) uygulanan duyarlılık analizi ve senaryo denemeleri, halk sađlıđı zerinde nemli tahminler yapmaya olanak sađlamıřtır. Hava kirleticilerinin %20 azaltılması senaryosunda, Sađlık Etki Puanında sırasıyla %5.46 (XGBoost) ve %5.98 (SVR) dzeyinde net bir iyileřme saptanmıřtır. Hava kirleticilerinin %10 artırılması senaryosunda ise bařta kardiyovaskler vakalarda dikkat eken bir vaka artıřı gzlenmiřtir. Bu modellerin solunum yolu vakalarında ise kısa sreli deđiřimlerde gsterdiđi eliřkiler, solunum sistemi rneklerinin anlık hava temizliđinden veya kirliliđinden ziyade zaman iinde gecikmeli maruziyetle iliřkili olmasıyla aıklanmaktadır (Samet vd., 2000). En son senaryo olan, sıcaklıđın arttıđı ve nem ile rzgr hızının azaldıđı meteorolojik deđiřim senaryosunda ise Sađlık Etki Puanı zerindeki etkisinin gzle grnr dzeyde sınırlı kaldıđı belirlenmiřtir.

Sonuç olarak bu arařtırma; hava kirliliđinin halk sađlık zerindeki sıklık ve dađılım odaklı risk grafiklerinin izdirilmesinde ve deđiřime gre etki senaryolarının kurgulanmasında, dođrusal olmayan makine đrenmesi algoritmalarının yksek gvenilirlikte ve dřk sapmayla tutarlı modelleme imkanları sunduđunu yansıtmaktadır. Elde edilen bu bulgular dođrultusunda, geleceđe ynelik yapay zeka destekli řehir planlamalarına ve evre-sađlık ynetim politikalarına, tahminleme sistemlerinin dahil edilmesi, hali hazırda olan ya da potansiyel olabilecek riski tespit etmede ve tespit edilen riske karřı bir aksiyon alabilme de nemli rol oynamaktadır.

KAYNAKÇA

- [1] Agibayeva, A., Khalikhan, R., Guney, M., Karaca, F., Torezhan, A., & Avcu, E. (2022). An air quality modeling and disability-adjusted life years (DALY) risk assessment case study: Comparing statistical and machine learning approaches for forecasting. *Sustainability*, 14(24), Article 16641. <https://doi.org/10.3390/su142416641>
- [2] Akdeniz, F. (2012). *Regresyon analizi*. Nobel Akademik Yayıncılık.
- [3] ALŞAN, U. (2026). *Alzheimer hastalığının erken teşhisi için biyomarker verilerine dayalı makine öğrenimi modellerinin geliştirilmesi* (Tez No. 1005959) [Yüksek lisans tezi, ÜSKÜDAR ÜNİVERSİTESİ]. Ulusal Tez Merkezi.
- [4] Alpar, R. (2020). *Uygulamalı çok değişkenli istatistiksel yöntemler* (6. baskı). Detay Yayıncılık.
- [5] American Lung Association. (2023, 26 Ekim). *Nitrogen dioxide*. <https://www.lung.org/clean-air/outdoors/what-makes-air-unhealthy/nitrogen-dioxide>
- [6] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32.
- [7] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- [8] COŞAR, M. (2023). Yapay Zekâ, Teori ve Uygulamalar. Kılıç, S. (Ed), *Yapay Zekâ Bileşenleri ve Türleri*, (129-146), Nobel Yayınları, Ankara.
- [9] Çevre, Şehircilik ve İklim Değişikliği Bakanlığı. (t.y.). *Hava kalitesi indeksi*. Sürekli İzleme Merkezleri Dairesi Başkanlığı (DATHM). <https://dathm.csb.gov.tr/hava-kalitesi-indeksi-89066>
- [10] Çevre, Şehircilik ve İklim Değişikliği Bakanlığı. (2024). *Hava kalitesinde PM10 ve SO2 ortalamaları*. Çevresel Göstergeler. <https://cevresehgostergeler.csb.gov.tr/hava-kalitesinde-pm10-ve-so2-ortalamlari-85734>
- [11] Di, Q., Wang, Y., Zanobetti, A., Wang, Y., Koutrakis, P., Choirat, C., Dominici, F., & Schwartz, J. D. (2017). Air pollution and mortality in the medicare population. *The New England Journal of Medicine*, 376(26), 2513–2522. <https://doi.org/10.1056/NEJMoa1702747>
- [12] DİANATİ, A. (2026). *Türkiye'nin hanehalkı tüketiminde engel yasasının makine öğrenmesi yöntemleri ile incelenmesi* (Tez No. 1001935) [Yüksek

lisans tezi, İSTANBUL NİŞANTAŞI ÜNİVERSİTESİ]. Ulusal Tez Merkezi.

- [13] Dockery, D. W., Pope, C. A., Xu, X., Spengler, J. D., Ware, J. H., Fay, M. E., Ferris, B. G., & Speizer, F. E. (1993). An association between air pollution and mortality in six US cities. *The New England Journal of Medicine*, 329(24), 1753–1759. <https://doi.org/10.1056/NEJM199312093292401>
- [14] Dominici, F., Peng, R. D., Bell, M. L., Pham, L., McDermott, A., Zeger, S. L., & Samet, J. M. (2006). Fine particulate air pollution and hospital admission for cardiovascular and respiratory diseases. *JAMA*, 295(10), 1127-1135.
- [15] El Kharoua, R. (2024). *Air quality and health impact dataset* [Veri seti]. Kaggle. <https://www.kaggle.com/datasets/rabieelkharoua/air-quality-and-health-impact-dataset>
- [16] ESA Elektronik. (t.y.). *Ozon (O3) gazı nedir?* [https://www.esaelektronik.com/ozon-\(o3\)-gazi-nedir](https://www.esaelektronik.com/ozon-(o3)-gazi-nedir)
- [17] FELEK, D. (2025). *Klasik lineer regresyon üzerine bir çalışma* (Tez No. 934300) [Yüksek lisans tezi, ORDU ÜNİVERSİTESİ]. Ulusal Tez Merkezi.
- [18] Fotopoulou, E., Zafeiropoulos, A., Papaspyros, D., Hasapis, P., Tsiolis, G., & Bouras, T. (2015). *A big data framework for assessing the health impact of air pollution* [Doctoral dissertation, National Technical University of Athens]. ProQuest Dissertations and Theses Global. <https://www.proquest.com/openview/70963e3a8bf23dd0cd524fd74753cf08/1>
- [19] Fotopoulou, E., Zafeiropoulos, A., Papaspyros, D., Hasapis, P., Tsiolis, G., & Bouras, T. (2015). A linked data framework for assessing the health impact of air pollution. *Proceedings of the 2015 IEEE International Conference on Big Data (Big Data)*, 2307–2314. <https://doi.org/10.1109/BigData.2015.7368881>
- [20] Friedman, J., Hastie, T., & Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, 33(1), 1–22.
- [21] Gore, R. W., & Deshpande, D. S. (2017). An approach to predict "Unhealthy for Sensitive Groups" air quality index category using data mining. *Proceedings of the International Conference on Inventive Computing and Informatics (ICICI)*, 442–447. <https://doi.org/10.1109/ICICI.2017.8122148>
- [22] Gujarati, D. N., & Porter, D. C. (2009). *Basic econometrics* (5th ed.). McGraw-Hill.

- [23] Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2018). *Multivariate data analysis* (8th ed.). Cengage Learning.
- [24] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2. baskı). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- [25] Hoerl, A. E. ve Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1), 55-67.
- [26] James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning: With Applications in R*. Springer.
- [27] Karaaslan, A., Çebi Karaaslan, K. ve Kardeş, S. (2025). Disentangling the determinants of household energy expenditure: A quantile regression approach with machine learning. *Energy and Buildings*, 349, 116577. <https://doi.org/10.1016/j.enbuild.2025.116577>
- [28] Kelly, F. J., & Fussell, J. C. (2011). Air pollution and airway disease. *Clinical & Experimental Allergy*, 41(8), 1059-1071. <https://doi.org/10.1111/j.1365-2222.2011.03776.x>
- [29] Kelly, F. J., & Fussell, J. C. (2015). Air pollution and public health: Emerging hazards and improved understanding of risk. *Environmental Geochemistry and Health*, 37(4), 631–649.
- [30] Khaldi, M., Erraissi, A., Hain, M. ve Banane, M. (2025). Comparative Analysis of Supervised Machine Learning Classification Models. *Lecture Notes in Networks and Systems*.
- [31] Kim, J., & Chun, S. (2020). Prediction of concentrations using Han River basin weather station data and Google Trends. *Scientific Reports*, 10, Article 14526. <https://doi.org/10.1038/s41598-020-71408-w>
- [32] Li, C., Chen, H., Li, J., Dong, Z., Gao, Y., Zeng, S., Wang, Y., Xu, H., Pan, C., & Chen, Z. (2022). High-resolution mapping of ambient and its health impacts using a coupled machine learning and big data framework. *Environmental Science & Technology*, 56(17), 12345–12355. <https://doi.org/10.1021/acs.est.2c03027>
- [33] Liao, J., Fu, Q., & Chen, L. (2025). Spatial-temporal prediction of and concentrations in southern Chile using machine learning and logistic regression. *Atmosphere*, 16(12), Article 1377. <https://doi.org/10.3390/atmos16121377>
- [34] Liao, J., Tu, Y., Chien, L. C., & Chen, L. C. (2020). Association between long-term exposure to ambient air pollution and physical frailty in older adults: A nationwide cohort study. *Journal of Cleaner Production*, 246, Article 118825. <https://doi.org/10.1016/j.jclepro.2019.118825>

- [35] Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. In *Advances in neural information processing systems* (Vol. 30, pp. 4765–4774). Curran Associates, Inc.
- [36] Mainka, A. ve Žak, M. (2022). Synergistic or antagonistic health effects of long- and short-term exposure to ambient and : A review. *International Journal of Environmental Research and Public Health*, 19(21), Makale 14079. <https://doi.org/10.3390/ijerph192114079>
- [37] Montgomery, D. C., Peck, E. A., & Vining, G. G. (2021). *Introduction to linear regression analysis* (6. baskı). John Wiley & Sons.
- [38] OKUTUCU, H. (2026). *Akıllı şehirlerde makine öğrenmesi yöntemleri ile trafik yoğunluğu tahmini ve bir vaka çalışması* (Tez No. 1006623) [Yüksek lisans tezi, İSTANBUL AYDIN ÜNİVERSİTESİ]. Ulusal Tez Merkezi.
- [39] Öztürk, M. (2021, 27 Kasım). *Görünmez sessiz katil PM10 ve PM2.5 kirliliği*. Independent Türkçe. <https://www.indyturk.com/node/440731/t%C3%BCrki%C3%BCnmez-sessiz-katil-pm10-ve-pm25-kirlili%C4%9Fi>
- [40] Pathak, S., Kuchkorov, T., Yusupov, I., Makhkamov, B., Zaynidinov, K., & Ather, D. (2024). Urban air quality and health impact analysis based on machine learning models. *Proceedings of the IEEE International Conference*, Article 10957146. <https://doi.org/10.1109/10957146>
- [41] Pope, C. A., Burnett, R. T., Thun, M. J., Calle, E. E., Krewski, D., Ito, K., & Thurston, G. D. (2002). Lung cancer, cardiopulmonary mortality, and long-term exposure to fine particulate air pollution. *JAMA*, 287(9), 1132-1141.
- [42] Rajesh, M., Babu, R. G., Moorthy, U., & Easwaramoorthy, S. V. (2025). Machine learning-driven framework for realtime air quality assessment and predictive environmental health risk mapping. *Scientific Reports*, 15, Article 14214. <https://doi.org/10.1038/s41598-025-14214-6>
- [43] Samet, J. M., Dominici, F., Currier, I., Coursac, I., & Zeger, S. L. (2000). Fine particulate air pollution and mortality in 20 U.S. cities, 1987–1994. *The New England Journal of Medicine*, 343(24), 1742-1749.
- [44] Shi, T., Zhang, Y., Yuan, X., Li, F., & Yan, S. (2024). Spatial patterns and determinants of concentrations: A land use regression analysis in Shenyang metropolitan area, China. *Sustainability*, 16(12), Article 5119. <https://doi.org/10.3390/su16125119>
- [45] Smola, A. J., & Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, 14(3), 199-222. <https://doi.org/10.1023/B:STCO.0000035301.49549.88>

- [46] ŞENEL KAHYAOĞLU, B. (2026). *Kalp hastalıklarının erken teşhisi için makine öğrenmesi algoritmalarının karşılaştırmalı performans analizi* (Tez No. 1003780) [Yüksek lisans tezi, YILDIZ TEKNİK ÜNİVERSİTESİ]. Ulusal Tez Merkezi.
- [47] Temirbekov, A., Temirbekova, S., Tamabay, A., Kasenov, A., Askarov, K., & Tukenova, N. (2023). Assessing the impact of air pollution on respiratory diseases in Almaty City using machine learning. *International Journal of Environmental Research and Public Health*, 20(18), Article 6770. <https://doi.org/10.3390/ijerph20186770>
- [48] Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1), 267-288. <https://doi.org/10.1111/j.2517-6161.1996.tb02080.x>
- [49] TOPSAKAL, G. (2026). *Oracle PL/SQL ve Oracle Forms uygulamalarında performans optimizasyonu* (Tez No. 1004235) [Yüksek lisans tezi, MALTEPE ÜNİVERSİTESİ]. Ulusal Tez Merkezi.
- [50] Vapnik, V. N. (1995). *The nature of statistical learning*. Springer.
- [51] YÜKSEL, Ö. S. (2026). *Yapay zeka ve nesnelerin interneti kullanılarak toprak analizine bağlı en ekonomik sulama sistema ile ekilebilir bitki çeşitliliği tespiti* (Tez No. 1000192) [Yüksek lisans tezi, ÇANKIRI KARATEKİN ÜNİVERSİTESİ]. Ulusal Tez Merkezi.